

Subject: _____

Year. _____ Month. _____ Date. ()

ML - 5th SESSION

exponential family o

natural parameter function

$$p_\theta(y) = \frac{1}{z(\theta)} h(y) \exp(t^\theta \uparrow \theta^T s(y))$$

↳ sufficient statistic

for most of distribution $s(y) = y$

II Generalized linear models:

: ينبع الموديلات الخطية من توزيعات معينة

$$Y|x, \theta \sim N(\mu, \sigma^2)$$

$$Y|x, \theta \sim \text{Bernoulli}(\theta)$$

Normal distribution:

$$f(x) = E(Y|x; \theta) = \mu = \beta^T x$$

$g(z) = z$ due identity link function

Bernoulli distribution:

$$f(x) = E(Y|x; \theta) = \theta = g(\beta^T x) \quad g(z) = \frac{1}{1+e^{-z}}$$

g: response function

التابع المرتبط هو الذي يربط بين المتغير المستقل والمتغير المداري

g^{-1} : link Function

$$g^{-1}(\theta) = \beta^T x \quad \xrightarrow{\text{logistic Reg}} \log \frac{\theta}{1-\theta} = \beta^T x$$

Subject:

Year. Month. Date. ()

glm یعنی family exponential family از نسبت توزیع $Y|x; \theta$ پیشگویی میکند glm یعنی

پیشگویی β با $\underline{\text{مود}} = \text{نیمه مولید}$ و $\underline{\text{مود}} = \text{نیمه مولید}$

$$Y = F(x) = g(B^T x)$$

ستوانه خطی \leftarrow \downarrow linear predictor

gene یعنی گلرید است که (Y) یعنی میزان پوشیدگی میباشد (مثال)

جنس \rightarrow gender یعنی x_1 , treatment/control یعنی x_2 , سنه hit

برای مثال $Y|x \sim \text{Poisson}(\lambda)$ خوب است.

• GLM چهار ماده

• exponential family از نسبت توزیع $Y|x; \theta$ ①

$$P(y|x; \theta) = \frac{1}{Z(\theta)} h(y) \exp(t(\theta)^T s(y))$$

depends on $B\beta x + t$

suppose $s(y) = y$

redesign choice $t(\theta) = B^T x$ خود را فرموده ②

$$F(x) = E(Y|x; \beta) = g(B^T x) \quad \text{③}$$

• $F(x)$ چند مدل را عرض میکند *

Subject: _____

Year. _____ Month. _____ Date. ()

example : Bernoulli distribution

$$Y|x; \beta \sim \text{Bernoulli}(\theta)$$

$$\textcircled{1} f(x) = E(Y|x, \beta) = \theta *$$

$$\textcircled{2} t(\theta) = \log \frac{\theta}{1-\theta} = \beta^T x$$

$$\frac{\theta}{1-\theta} = e^{\beta^T x} \rightarrow (1-\theta)e^{\beta^T x} = \theta \Rightarrow \theta = \frac{1}{1+e^{-\beta^T x}}$$

$$\xrightarrow{*} f(x) = \theta = \frac{1}{1+e^{-\beta^T x}} \Rightarrow g(z) = \frac{1}{1+e^{-z}}$$

example: normal distribution

$$Y|x; \beta \sim N(\mu, 1)$$

$$\textcircled{1} t(\mu) = \mu = \beta^T x$$

$$\textcircled{2} f(x) = E(Y|x, \beta) = \mu$$

$$\Rightarrow f(x) = \beta^T x \rightarrow g(z) = z$$

example: poisson distribution

$$Y|x; \beta \sim \text{Poisson}(\lambda)$$

$$P(Y|x; \beta) = \frac{\lambda^x e^{-\lambda}}{x!}$$

Hence \rightarrow exponential Family of poisson

$$\textcircled{1} t(\lambda) = \log \lambda = \beta^T x$$

$$\textcircled{2} f(x) = E(Y|x; \lambda) = \lambda$$

$$\log \lambda = \beta^T x \Rightarrow f(x) = \lambda = e^{\beta^T x}$$

$$g(z) = e^{z\beta}$$

Subject:

Year. Month. Date. ()

هدف تغییر هاست

$$\Rightarrow L(\beta) = \prod_{i=1}^n P(y[i] | x[i], \beta)$$

$$= \prod_{i=1}^n \frac{\lambda^{y[i]} e^{-\lambda}}{y[i]!} \lambda = e^{B^T x} \frac{\prod_{i=1}^n \exp(B^T x[i])^{y[i]}}{\prod_{i=1}^n y[i]!}$$

الزعم يرى $\nabla L(B)$ likely to be $\nabla^2 L(B)$ متساوياً

الاستاذ عبد العليم و تفاصيله و تفاصيل حمل شهادته

□□ softmax regression ?

پیو از جنگلی مونومال (Multiclass) یا کلasse

جبریل رسالہ اسی میں exponential family size

عمره تسعين عاماً و

univariant: $X \sim N(\mu, \sigma^2) \Rightarrow P(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right)$

$$\text{multivariate: } P(x; \mu, \Sigma) = \frac{1}{(2\pi)^{\frac{p}{2}} |\Sigma|^{\frac{1}{2}}} \exp(-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu))$$

quadratic in x

MEIR P

$$E(X) = \mu$$

$$\Sigma \in \mathbb{R}^{P \times P}$$

L. E. H.

$$x = (x_1, \dots, x_p) \quad \text{cov}(x) = E((z - E(x))^T) = \sum_{z \sim P} \text{cova}_z$$

Subject:

Year. Month. Date. ()

شکل ۲۲۹ توزیع داده ای که در مجموع ۴۰۰ نمونه دارد. CSS229 و part ۳-۵ می‌بینیم که از این داده ای محتراس است و قدر توزیع بالاتر می‌باشد.

① Discriminative versus Generative models

پرسید: مدل است زیرا می‌باشد توزیع احتمال سطحی $P(Y|X)$ ؟

وای functional مدل فرم می‌باشد. SVM ، kNN ، logistic هست.

$$P(Y|X, \beta) = \frac{1}{1 + e^{-\beta^T X}} \quad \text{بر اساس راندگانی تغییر می‌نماید}$$

از $P(X, Y)$ برای statistical مدل: Generative

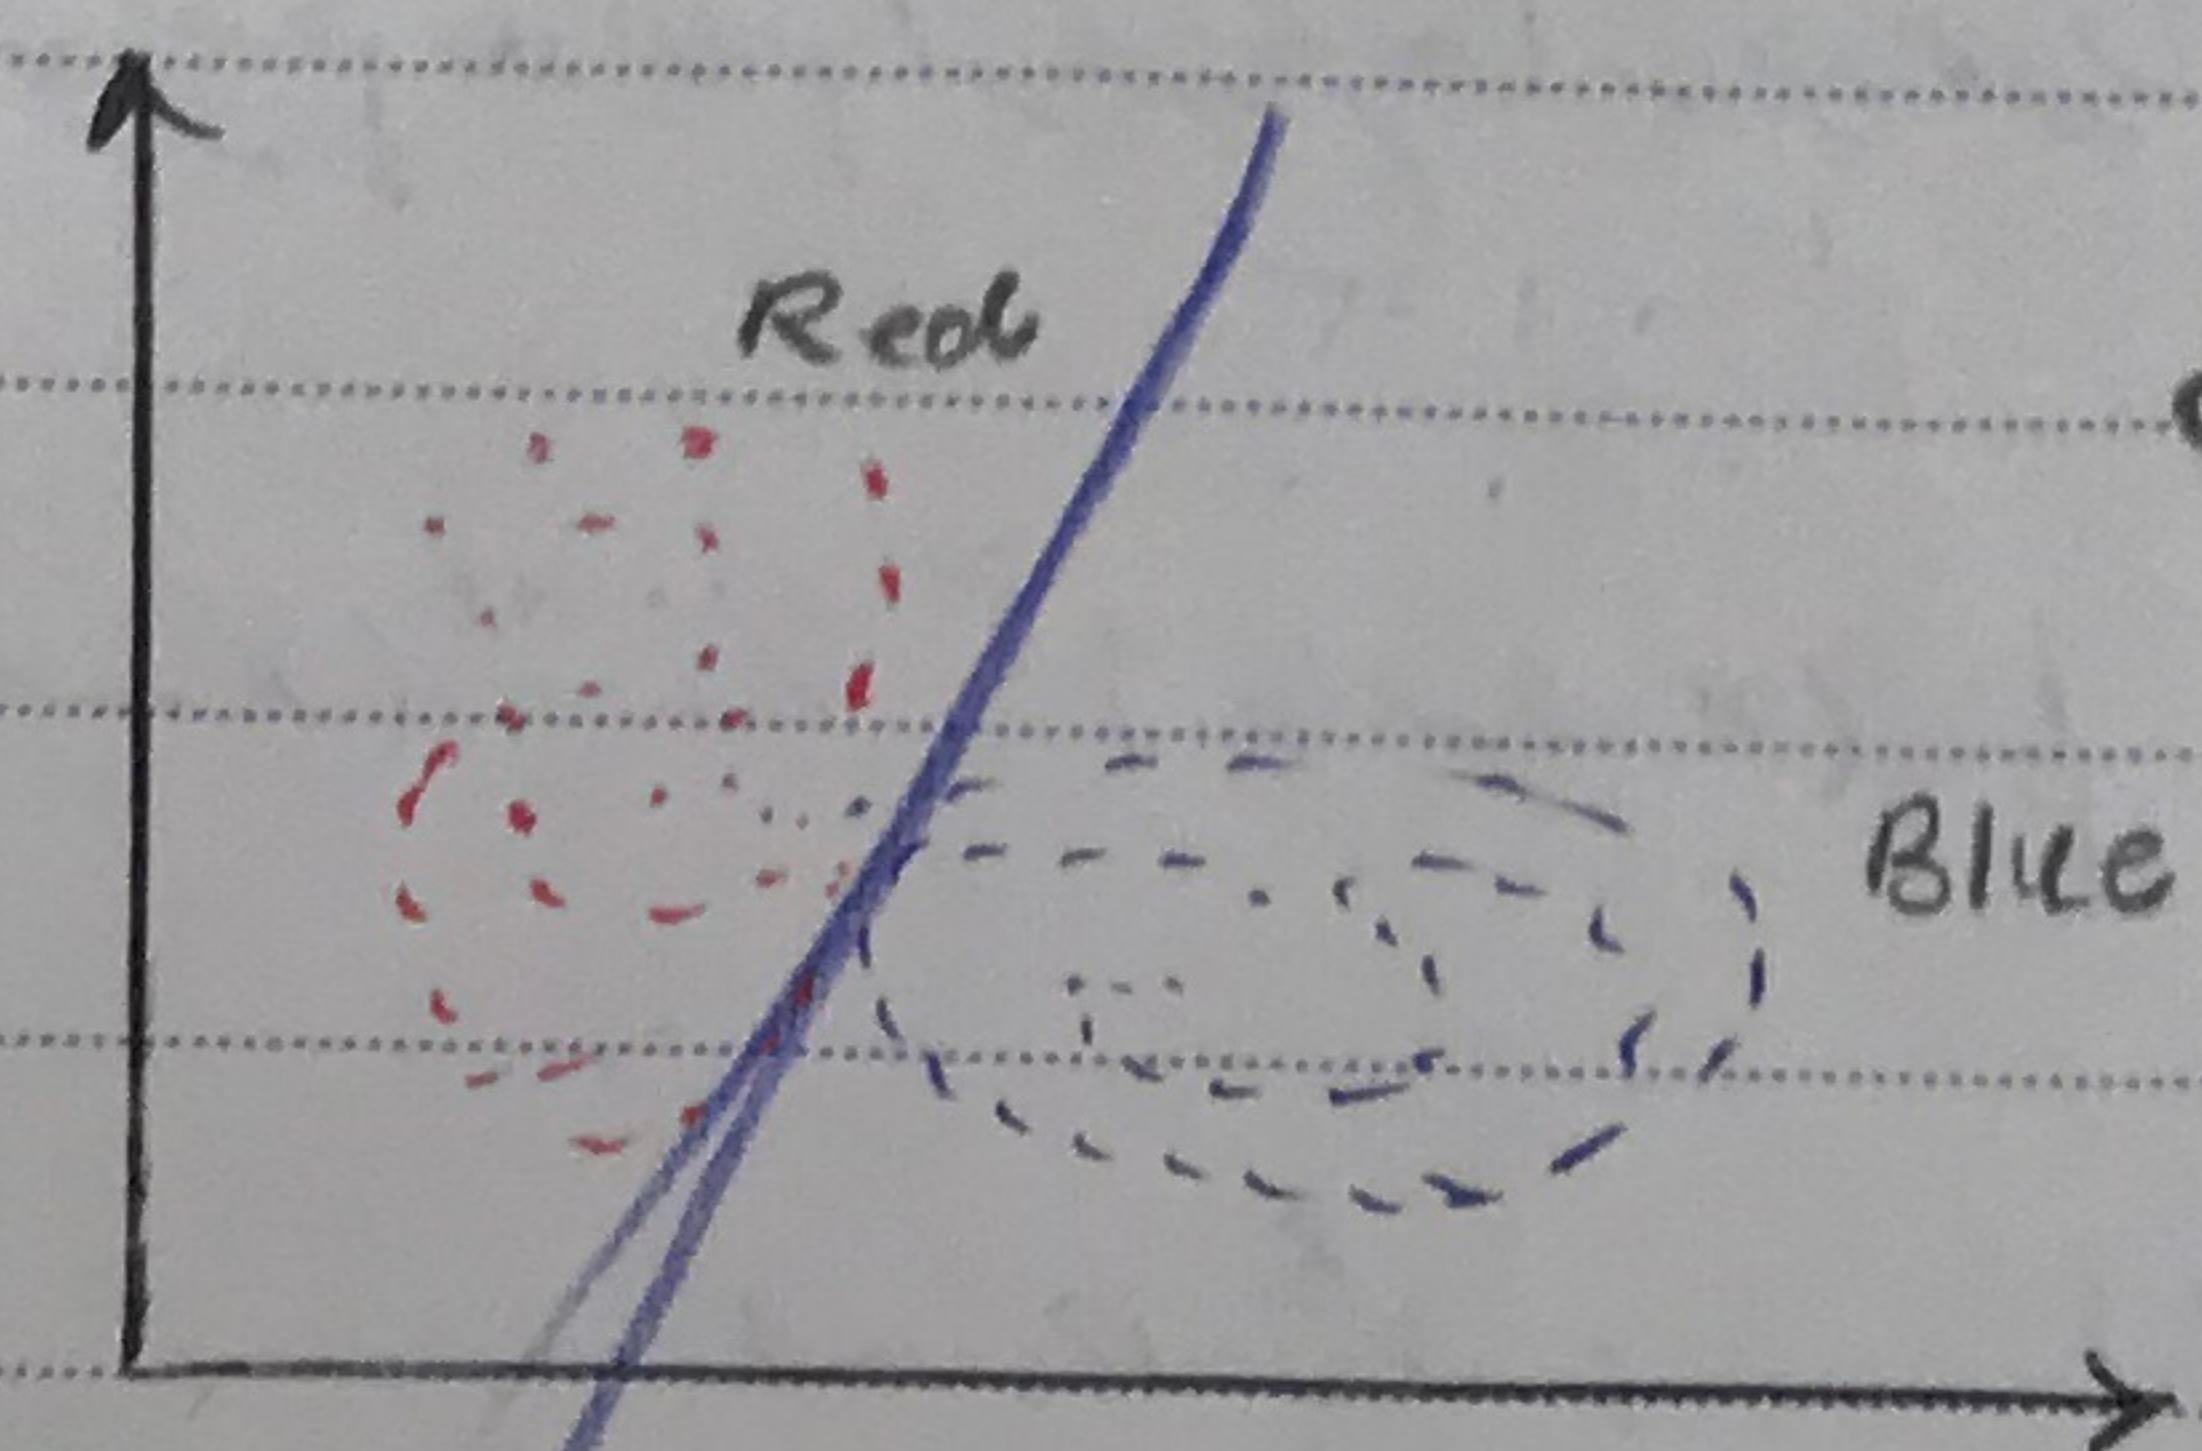
$$\circ P(X, Y) = P(X) P(Y|X)$$

$$\circ P(X, Y) = \underbrace{P(Y)}_{\text{از داده}} \underbrace{P(X|Y)}_{\text{از داده}}$$

است. با استفاده از این این $P(Y|X)$ بایزی مدل Bayes classification می‌باشد.

$$P(Y|X) = \frac{P(X|Y) P(Y)}{P(X)}$$

NB , HMM ، LDA :



نحوه این مدل را Discriminative مدل می‌نامند.

برای مدل معکوس می‌باشد $P(Y=B|X)$

طبیعت این احتمال بزرگ نمایند.

$P(Y=B), P(Y=R), P(X|Y=R), P(X|Y=B)$ از توزیع مدل generative مدل می‌باشد.

Subject:

Year. Month. Date. ()

لکابی حفظ داری این $P(X|Y)$ را تابعه بین عبارت هست.

هریت مدل Generative LDA این است که مدل تولید دنیا را بر سر می‌گیریم.

Linear Discriminant Analysis :

این مدل generative LDA است و دستیاری داریم که مثل قبل است و این این است که توزیع X را کسی

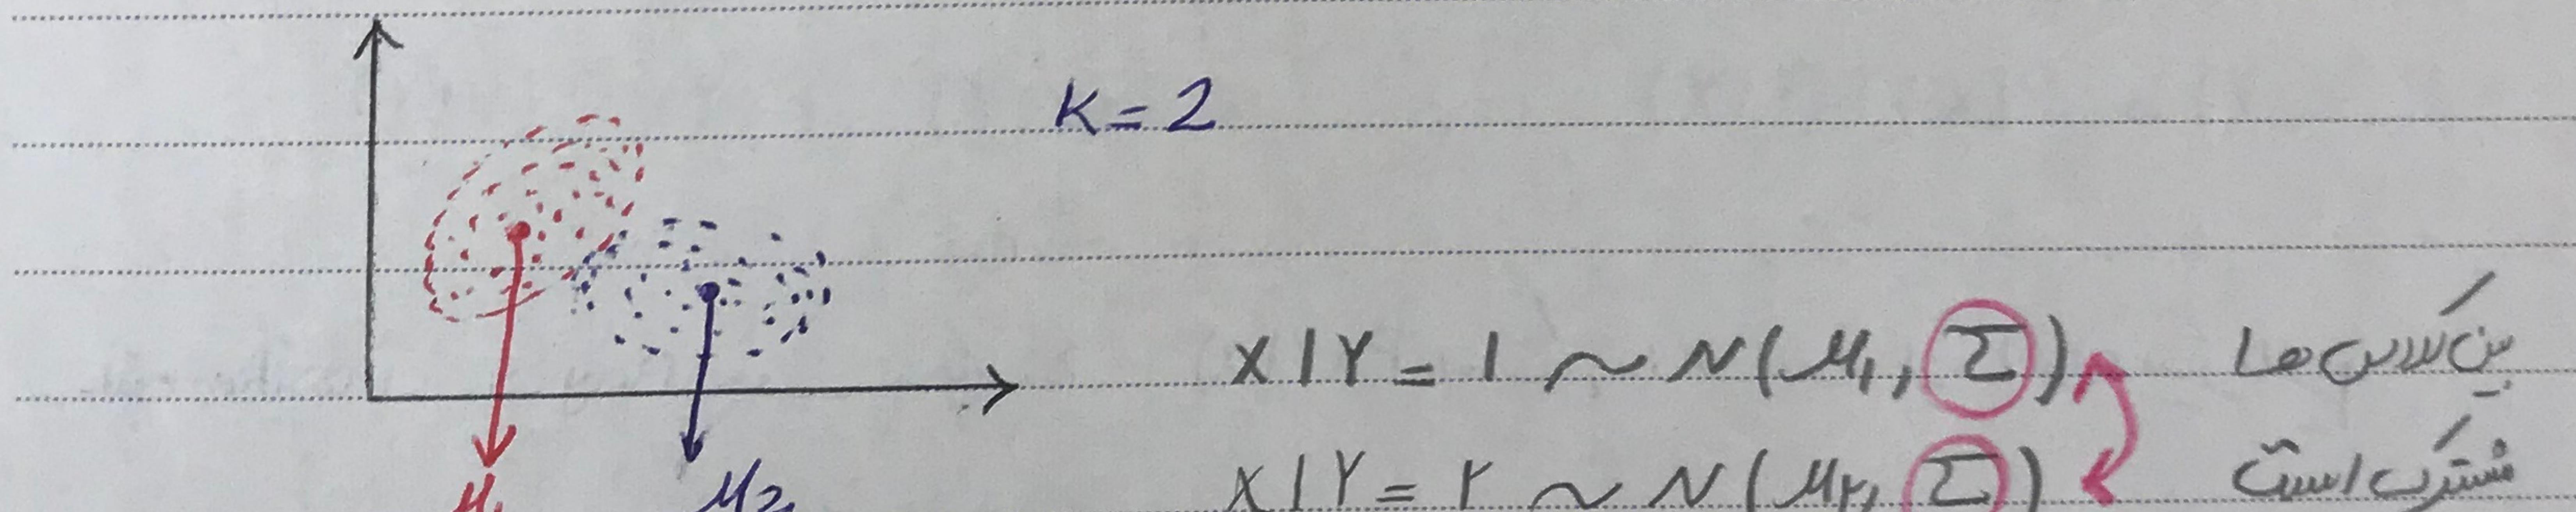
هر لام مدل سیم در واقع حرف عبارت دو توزیع را دارد:

$$P(X|Y=k) \quad \& \quad P(Y)$$

$X \in \mathbb{R}^P$

$$D = \{(x_{(1)}, y_{(1)}), (x_{(2)}, y_{(2)}), \dots, (x_{(n)}, y_{(n)})\} \quad y \in \{1, 2, \dots, K\}$$

$$P(Y=k|x) = \frac{P(X|Y=k)P(Y=k)}{P(X)} \quad \begin{array}{l} \text{اعرض چنانچه این است که این} \\ \text{برای کدام توزیع مدل دارد} \end{array}$$



حال می‌توانیم از توزیعها برای پیش‌بینی استفاده کنیم.

$$P(X|Y=k) = \frac{1}{(2\pi)^{P/2} |\Sigma|^k} \exp\left(-\frac{1}{2} (x - \mu_k)^T \Sigma^{-1} (x - \mu_k)\right)$$

$$P(Y=k) = R_k \quad (\text{multinomial}) \quad : \sum_{i=1}^K R_i = 1$$

Subject:

Year..... Month..... Date..... ()

نحوين لـ $P(Y=k|x)$ ارجع لـ $P(Y=k)$ و $P(x|Y=k)$ من $P(x)$ و $P(Y=k)$ من $P(Y=k)$.

• $P(Y=k|x) = \frac{P(x|Y=k)P(Y=k)}{P(x)}$

$$G(x) = \operatorname{argmax}_K P(Y=k|x) = \operatorname{argmax}_K \log P(Y=k|x)$$

$$= \operatorname{argmax}_K \log \left(\frac{P(x|Y=k)P(Y=k)}{P(x)} \right) = \operatorname{argmax}_K (\log P(x|Y=k) + \log P(Y=k))$$

$$\begin{aligned} & \frac{\partial}{\partial K} \operatorname{argmax}_K \left(-\frac{1}{P} (x - \mu_K)^T \Sigma^{-1} (x - \mu_K) + \log R_K \right) \\ &= -\frac{1}{P} (x^T \Sigma^{-1} x - \underbrace{x^T \Sigma^{-1} \mu_K}_{\text{constant}} - \underbrace{\mu_K^T \Sigma^{-1} x + \mu_K^T \Sigma^{-1} \mu_K}_{\text{constant}}) \\ &= -\frac{1}{P} \underbrace{x^T \Sigma^{-1} x}_{\text{only depends on } K} + x^T \Sigma^{-1} \mu_K - \frac{1}{P} \mu_K^T \Sigma^{-1} \mu_K \end{aligned}$$

$$\Rightarrow \delta_K(x) = x^T \Sigma^{-1} \mu_K - \frac{1}{P} \mu_K^T \Sigma^{-1} \mu_K + \log R_K$$

لـ $\delta_K(x)$ يعطى قيمة مفيدة.

• $P(Y=k|x)$ يعطى احتمال ظهور y_k في حال ظهور x .

Data = $\{(x[1], y[1]), \dots, (x[n], y[n])\}$

$$L(\theta) = \prod_{i=1}^n P(x[i], y[i] | \theta) = \prod_{i=1}^n P(x[i]|y[i]) P(y[i])$$

Subject: _____

Year. _____ Month. _____ Date. _____ ()

$$\underset{2 \log}{\rightarrow} \ell(\theta) = \sum_{i=1}^n (\log P(x[i]|y[i]) + \log P(y[i]))$$

حالات معرفی می شوند و مدل برآورده شود:

$$\ell(\theta) = \sum_{y[i]=1} \log P(x[i]|y[i]=1) + \sum_{y[i]=2} \log P(x[i]|y[i]=2)$$

$$+ \sum_{i=1}^n \log P(y[i])$$

پارامتر $\hat{\mu}_k$, $\hat{\Sigma}$, $\hat{\pi}_k$ تابع MLE؛ اولین نتایج

$$\hat{\mu}_k, \hat{\Sigma}, \hat{\pi}_k = \operatorname{argmax} \ell(\theta)$$

$$K \text{ سریع: } n_k = \sum_{i=1}^n I(y[i]=k)$$

$$\hat{\mu}_k = \frac{\sum_{i=1}^n x[i] I(y[i]=k)}{n_k}$$

$$\hat{\Sigma} = \sum_{k=1}^K \sum_{y[i]=k} \frac{(x[i] - \hat{\mu}_k)(x[i] - \hat{\mu}_k)^T}{n - K}$$

$$\hat{\pi}_k = \frac{n_k}{n}$$

• Quadratic discriminant analysis (QDA)

* تفاوت این روش با LDA چیزی است که در QDA می خواهیم داد که x را در کلاس k بدانیم

$$\delta_k(x) = -\frac{1}{2} \log |\Sigma_k| - \frac{1}{2} ((x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k)) + \log \pi_k$$

آنکه x را در کلاس k بدانیم و در رابطه با $\delta_k(x)$ قرار داشته باشد

Subject:

Year. Month. Date. ()

وتحاول \hat{LDA} لـ LDA بـ λ داره راهی است برای داده های متریک خارج.

•• Regularized QDA

$$\frac{\lambda}{K} (\alpha) = \alpha \sum_{k=1}^K + (1-\alpha) \sum_{C \neq k} \rightarrow \text{the same as LDA}$$

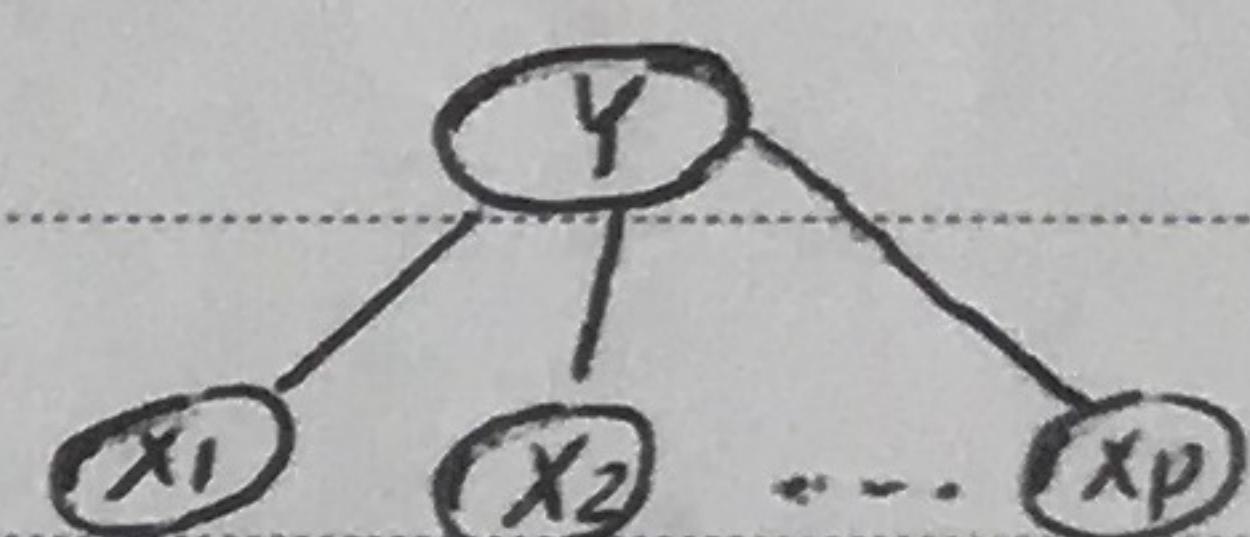
□□ Naive Bayes classifier:

پیشگویی، $P(X, Y) = P(X|Y)P(Y)$ ، قاعده generative پیشگویی

و نیز قاعده $P(Y|X)$ باشد که X پیشگوی Y است این طریق این قاعده در این شکل دارد.

$$P(X|Y) = P(x_1|Y) P(x_2|Y) \dots P(x_p|Y)$$

\hookrightarrow conditional independent



$$P(Y|X) = \frac{P(Y, X)}{P(X)} = \frac{P(x_1|Y) P(x_2|Y) \dots P(x_p|Y) P(Y)}{P(X)}$$

و قاعده $P(x_i|Y)$ و $P(Y)$ را میتوانیم با روش‌هایی که قاعده (ساده) تغییرات را در مدل می‌دانیم.

$$L(\theta) = \prod_{i=1}^n P(\mathcal{J}[i], x[i], \theta) = \prod_{i=1}^n P(x[i]|y[i]) P(y[i])$$

$$= \prod_{i=1}^n P(x_1[i]|y[i]) \dots P(x_p[i]|y[i]) P(y[i])$$

Subject:

Year. Month. Date. ()

$$\Rightarrow \log(L(\theta)) = \sum_{i=1}^n [\log(x_{1i} | y_{i1}) + \dots + \log(x_{pi} | y_{i1}) + \log P(y_{i1})]$$

Example : $X, Y \sim \text{Bernoulli}$

$\begin{matrix} (A) \\ \text{Age} \end{matrix}, \begin{matrix} (S) \\ \text{Smoke} \end{matrix}, \begin{matrix} (L) \\ \text{Lung Cancer} \end{matrix}$

$$P(L|A, S) = ?$$

$$P(L) \leftarrow \begin{matrix} P(L=1) = \theta = \frac{1}{2} \\ P(L=0) = (1-\theta) = \frac{1}{2} \end{matrix}$$

$$P(A|L) \rightarrow P(A=1|L=1) = \frac{1}{2}$$

$$P(A=1|L=0) = \frac{1}{2}$$

$$P(S|L) \rightarrow P(S=1|L=1) = \frac{1}{2}$$

$$P(S=1|L=0) = \frac{1}{2}$$

حال سوال $S=1, A=1$ حال $L=1$ را فرضیه کنید:

$$P(L=1|S=1, A=1) \propto P(A=1|L=1) P(S=1|L=1) P(L=1) = \frac{1}{2}$$

$$P(L=0|S=1, A=1) \propto P(A=1|L=0) P(S=1|L=0) P(L=0) = \frac{1}{2}$$