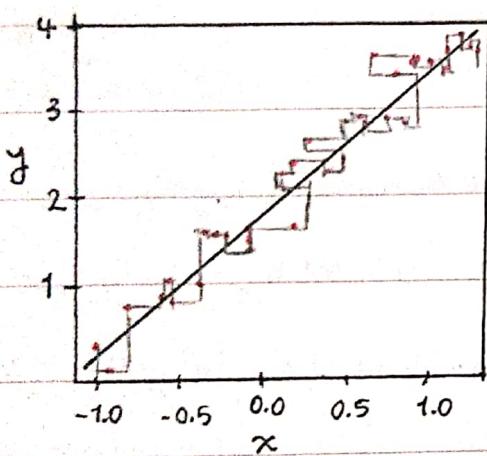


ML.7

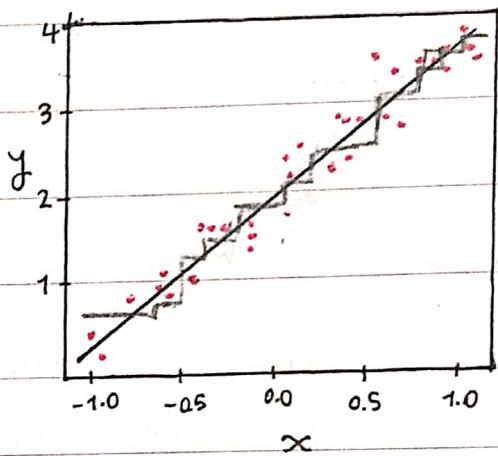
دستی مدلی مسایع و پیش‌نمود
classification, logistic regression

linear regression, KNN و مدل‌های داده خواهد

K-nearest neighbor regression



$K=1$



$K=9$

Ref: ISL book, Fig 3.17

خانواده مدل‌های همگن شده در KNN وقتی $K=1$ باشد، KNN مدل‌های خطی ای است و درجه k-برآورده شود مدل ساده تری نیست. در تاب ISL کسری مماثله می‌شوند، KNN، LR و KNN

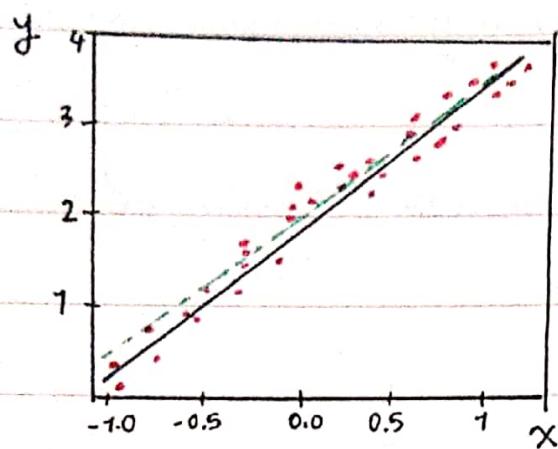
در نظر 3.18 تاب ISL، با خصوصیات مدل مشخص است (خط ساده کرد)، کسری

linear regression است این مدل آنکه از خط آنکه مدل مشخص است (least squares fit) می‌باشد.

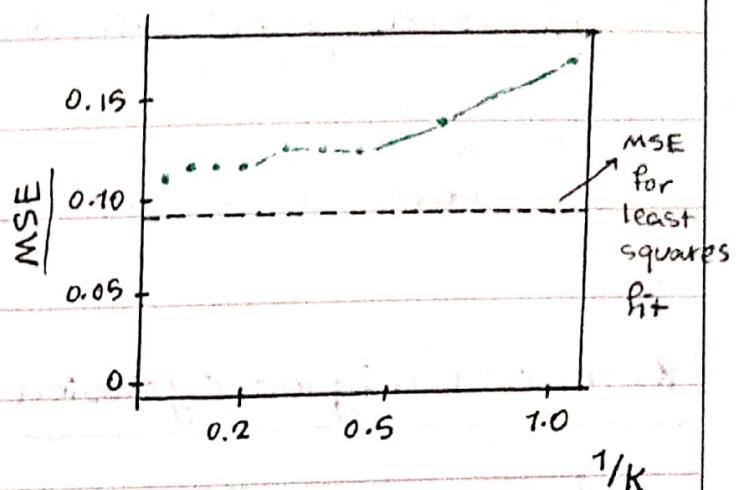
دراجی نادیده گردید و کاربردها کاربردهای KNN از KNN استفاده کرد.

باید K-عی خلقت استفاده کرد.

least squares fit



The MSE

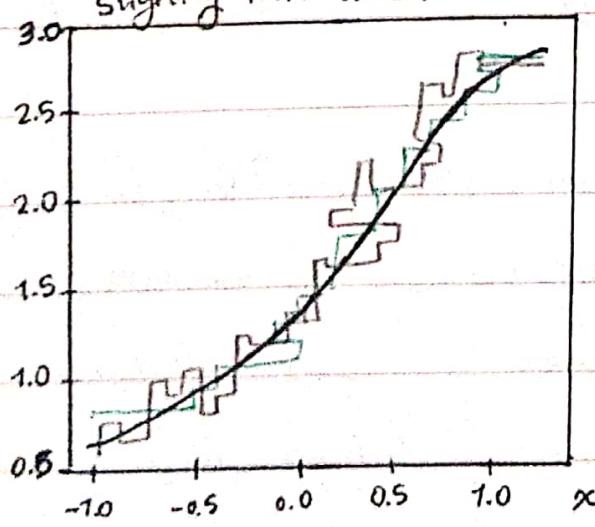


ISL book - Fig 3.18

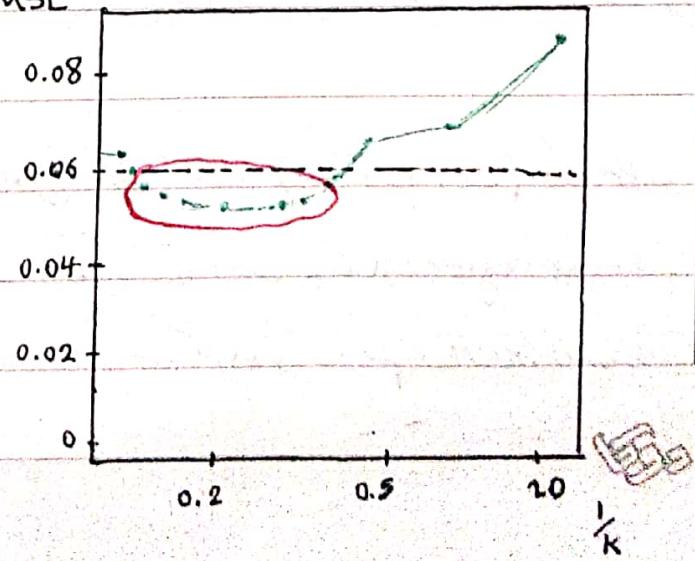
در مدل خطی $y = \beta_0 + \beta_1 x + \epsilon$ را با خطای سریع مشخص کرد ایس. دیسل
نموده است تا $\hat{y} = \bar{y}$ باشد. $MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y})^2$ می‌باشد. خطای خطا در LR ایس. و خطای خطا در KNN می‌باشد.
شکل خطای خطا در LR ایس. و خطای خطا در KNN می‌باشد.
بنابراین معنای متریک K در LR ایس. این متریک همچو بزرگ شدن خطای خطا است.
و در KNN هرچه K بزرگتر باشد (معنی $\frac{1}{K}$ کوچکتر) بدل نمی‌بینید همچو بزرگ شدن خطای خطا است.
آن ترتیب متریک K است.

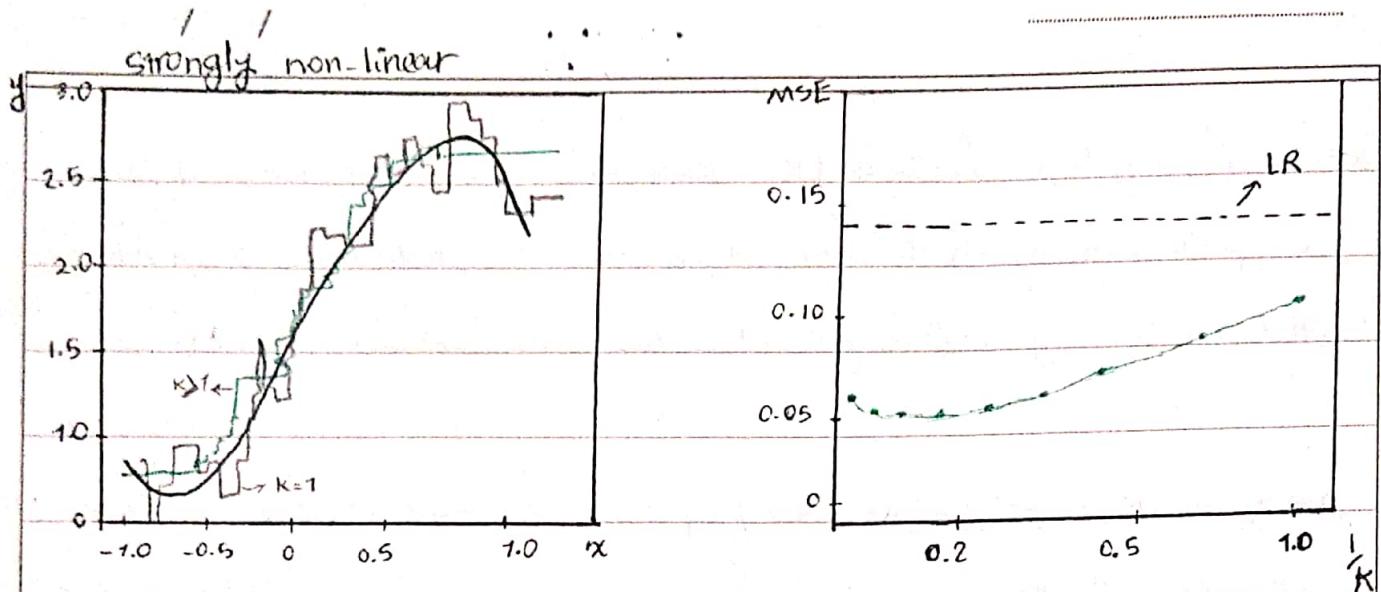
Non-linear relationship between X and Y

slightly non-linear



MSE





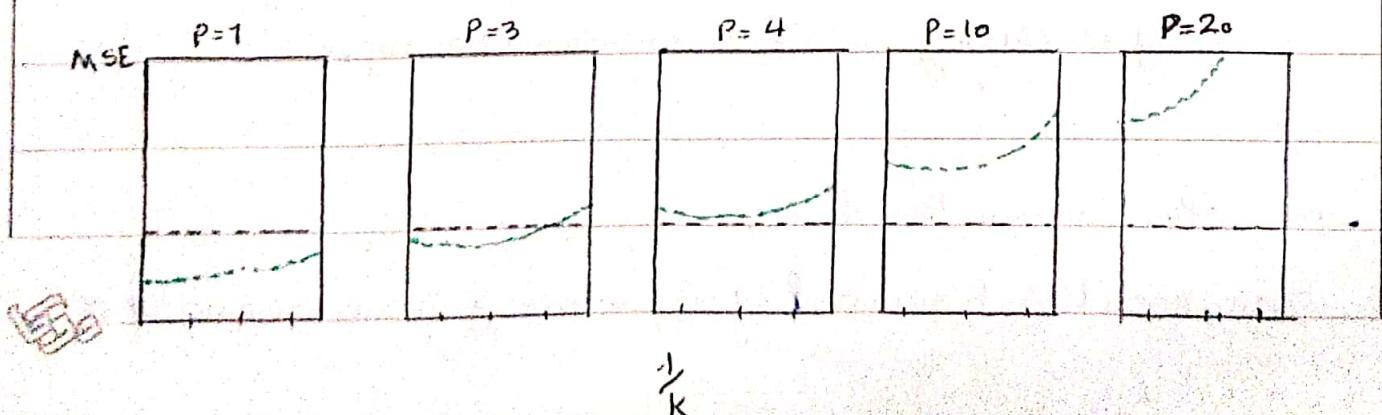
ISL book - Fig 3.19

KNN جزوی EK جزوی خوب چون خود را کمی می کند اما این امر برای داده های از پس از این داده های خوب نیست. این امر از این داده های خوب نیست. این امر از این داده های خوب نیست.

- K کوچک است و KNN جزوی خوب اما این امر برای داده های از پس از این داده های خوب نیست. این امر از این داده های خوب نیست.

Curse of dimensionality

- K observations that are close to x_0 may be very far away in p -dimensional space when p is large.
- By our definition, \hat{Y} only depends on the first predictor. The additional predictors are noise.



ISL book - Fig 3.20

- در مدل میل تر simulation انجام شد که KNN با LR مقایسه شود. خوب بدان این است که دل واعض صرخابی می باشد predictor یعنی آن روش ۲۰٪ تا سه تر هم داشته باشیم، دل داعض صرخابی از این دویستی است و عین آن روش Random اند و بعض ارتباطی می باشد و سایر predictor وجود ندارد.

- در عکس اول $P=1$ است و صرفاً می سقراً داریم و KNN علیرغم این شبیه به LR دارای هر چهار داده است. اگر این حی ماید جمل LR تغییر چینانی نماید این دلیل KNN خطای زیادی نماید. این predictor است. البته خطای LR هم کمتر از این است و آن هم به خاطر نوعی این noise است.

- دلیل این خطای KNN در اینجا بزرگترین دلیل فاصله میان تعیینی و در نظر نهاده این نقاط احتمالی سیار قوی است. در اینجا بزرگترین دلیل خطای زیادی data point داشته باشیم که فاصله بین چندین تردیک شوند.

Classification

- The response variable is qualitative/categorical.

$$D = \{(x[1], y[1]), \dots, (x[n], y[n])\}$$

example : 1) Input: gene expression data, response var: origin of cancer
 2) to classify an email to spam/non-spam

- we define a new loss function:

Zero-one loss function: $l(y + \hat{y})$ where \hat{y} is an estimate for y

دراخوا از لغتی خوبی و loss function ← استفاده حسکن

درین توقیف ناید مقادیر عیار که با پرداختی مسان نشید را بگیر. در واقعیت بخادر عیار که ایست را بدست حسکن misclassify

Training error rate :

$$\frac{1}{n} \sum_{i=1}^n I(y[i] \neq \hat{y}[i])$$

Test error:

$$E(I(y \neq \hat{y}))$$

unseen (وی را از expectation)

$$I \rightarrow \text{Indicator of } z \Rightarrow I(z) = \begin{cases} 1 & z = \text{True} \\ 0 & z = \text{False} \end{cases}$$

The Bayes classifier:

- Assign each data point to the most likely class, given its predictor values.

- هاست سوری در وکی اکسل حسکن از آن استفاده نموده وی در عمل عنوان آن را ساخت.

Formally, the Bayes classifier is defined.

$$\hat{y} = \arg \max_c P(Y=c | X)$$

ازای هر X ناریم، $P(Y=c)$ را صبیح کنیم.

بیشتر بوده عنوان \hat{y} در نظر گیری کردی.

- احاجی از جمل مذکور را عنی آوان در عمل حساب کرد؟ چون احاجی را ندارم، چون P همان خوبی-

- simulation داده و نتیجه آن را عنی لاتم. (و این P واقعی فعلاً در مرور در درم اعاده بینی موافق نه)

اما اگر P را داشتم $\hat{P}(x) = \hat{f}(x) + \epsilon$

- The Bayes error rate: $\rightarrow LR$ \rightarrow معادل خطای غریابی کافی $(\hat{P}(x) = \hat{f}(x) + \epsilon)$

* The Bayes classifier produces the lowest possible test error rate.

خوبی همین را عنی (خر)

$$1 - E \left(\max_c P(Y=c|x) \right)$$

expectation over all possible values for x

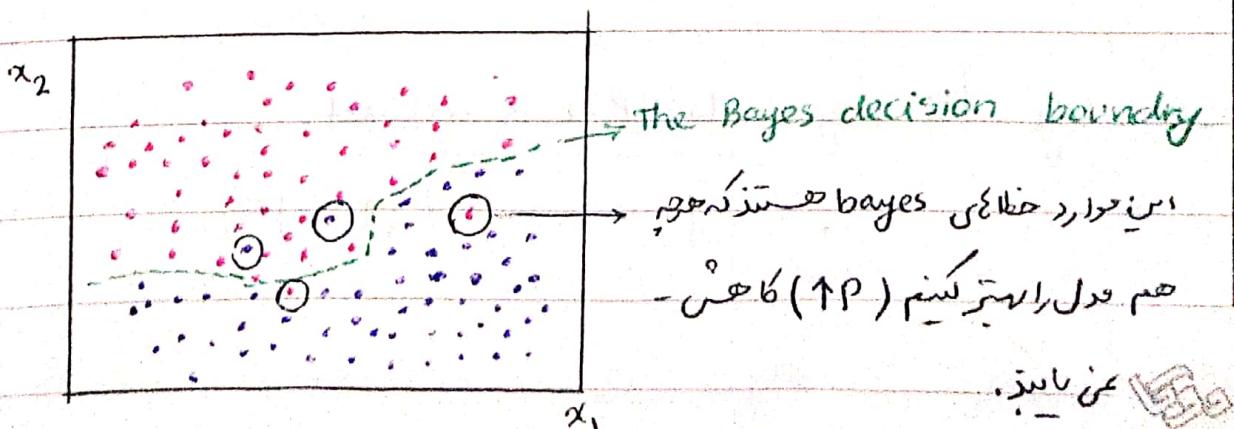
من خوبی سند باید x خاص در ۰.۹۵، ۰.۹۰، ۰.۸۵، ۰.۷۵، ۰.۶۵٪ مولود کارس $\frac{1}{2}$ خود

پس خوب اگر این طبقه هم باشد، ۱۰٪ خوب است \leftarrow error

. این معادل خطای غریابی کافی \rightarrow min LR

The Bayes Optimal decision boundary

- Two class problem:



- بازدید از نمونه های شبیه سازی و محدوده تصمیم بایسی را در حالتی که $P(Y|X)$ مشخص نباشد، Bayes decision boundary عینکوں از زیر استوار کرده.

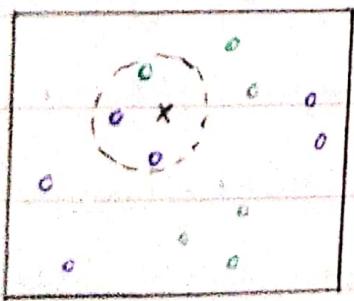
- * Given the generating density for each class, we can calculate the boundary exactly.

K-nearest neighbor classifier

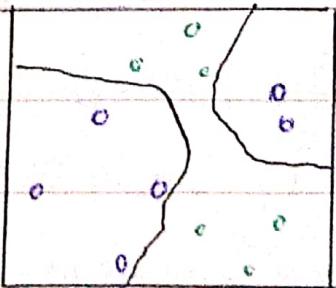
- * $P(Y|X)$ is not known for real data, so computing the Bayes classifier is impossible!
- * Many classifiers attempt to estimate $P(Y|X)$.
- * K-nearest neighbor classifier is such a method:

$$P(Y=c|X) = \frac{1}{k} \sum_{i \in N_k} I(Y[i] = c)$$

نحوی داده های $P(Y|X)$ را در آزمایش ML می خواهیم پیدا کرد، این روش را majority voting می نامیم، این روش کنترلی KNN classifier



نحوی KNN با $K=3$ است.

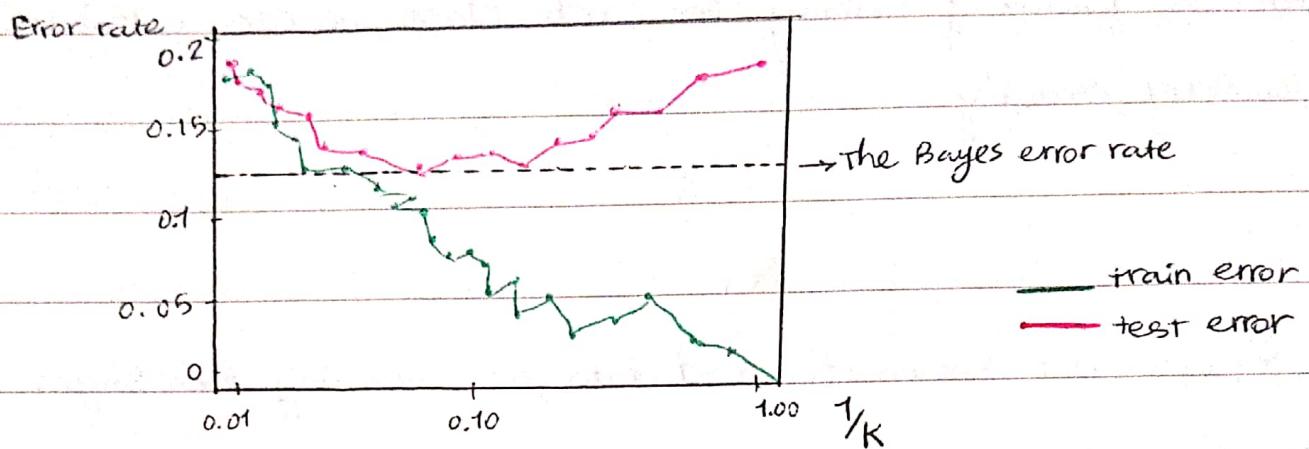


$K=3$

نحوی KNN با $K=3$ است.

Training and test error rates

- 200 training obs, 5000 test obs.



logistic regression

* Why not linear regression for classification problem?

- Approach:

- performing linear regression
 - And classifying according to $\hat{Y} > 0.5$

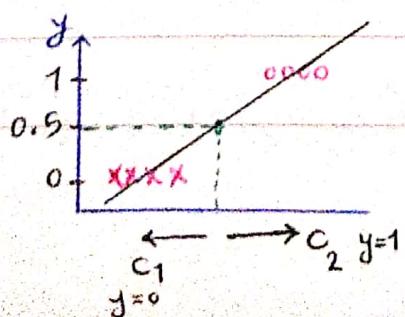
logistic regression نے مدل خطي اسٹ، اوسن سوال کہ متھی آئریاں اسٹ کہ اگر خواہم نہیں ملے۔

ـ الخطي / linear regression ; التصنيف / classification

ایدیہ: کے LR را ایک مدرجہم و classify رابرائیں اس سکے 0.5 لگانے پر ایک مدرجہم۔

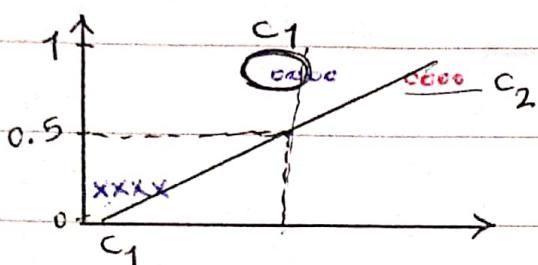
متغیر خروجی دوستی (Binary) دارد و مقدار آن ۰ یا ۱ است.

حتى تكون LR بسيطة، خطى بين نقاط fit حركته وآخر $y > 0.5$ بود، فيكون C_1 والآخر.



• $\text{curl } C_2 \text{ معنی} \Rightarrow y \leq 0.5$

حالا اگر بگوییم \hat{y} این مقدار را از تابع $f(x)$ می‌گیرد، در نهایت \hat{y} در دسترس است و می‌تواند به خوبی عمل کند.



لیکن اگر کار دستوریم این است که مقدار از \hat{y} را بین c_1 و c_2 بگیریم. بزرگتر از c_2 است و خارج از محدوده صفر و یک است. در نظر گرفته شود است.

*some estimates are outside $[0,1]$

-logistic regression

logistic regression هست که بر روی فرمولهای lineare extension را دارد تا بتوانند در

(binary classification,) روزانه استفاده کرد.

ایده که من حتماً این است که خروجی \hat{y} (force) را که تابع صفر و یک باشد.

Idea: enforce the responses to be in $[0,1]$

و قسمی هم که از خروجی حی سود پذیر است. مثلاً اگر $y = 0.2$ باشد، باحال
که کلاس ۱ متعلق است و مثلاً اگر $y = 0.9$ باشد بعنوان با احتمال ۹۰٪ بکلاس ۱
متعلق (درست)، چون که y برای کلاس ۱ را $\frac{1}{1+e^{-y}}$ در نظر گرفته ایم.

$$Z = \beta^T x = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3$$

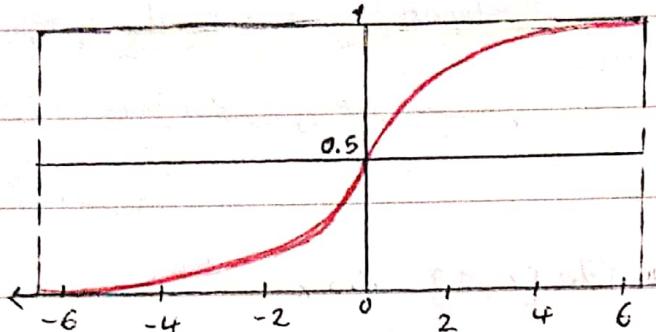
مقدار این عبارت می‌تواند بین $-\infty$ و $+\infty$ باشد. بنابراین Z را بایک تابع سکویی خواهد داشت.

بنابراین Z را بقفسی (logistic function or sigmoid function) می‌خواهیم صفر و یک را

$$0 < g(Z) < 1$$



$$g(f(z)) = \frac{1}{1 + e^{-z}} \rightarrow \begin{cases} g(z) = 0 & z = -\infty \rightarrow \text{أنتشار بخود} \\ g(z) = 0.5 & z = 0 \\ g(z) = 1 & z = +\infty \rightarrow \end{cases}$$



جداول Logistic regression مدلی clasifier است

$$f_{\beta}(x) = g(\beta^T x) = \frac{1}{1 + e^{-\beta^T x}}$$

این نکودا در logistic regression می خواهد که متغیرهای این داده ها را برآورد کند.

سین صعزوں کی حی دھدوانِ عدل کی سری ہارا امرکی خصوصی بحود را دارو۔

• How to estimate the parameters?

Given $D = \{(x[1], y[1]), \dots, (x[n], y[n])\}$

$$\in \mathbb{R}^d$$

$\rightarrow \in \{0,1\}$

فرصیات (Cvi logistic reg)

(نطري جي كرم) $y[n] \in \{-1, 1\} \cup \{0\}$ (يعني SVM، ω)

[درستیار چون در راصلیت Logistic، بیت احتمالی در عین آن حساب است.]

راحت تر باشد.

فان اگر خواهیم نکرد عدل احتمالات سازی:

$$Y = \text{Bernoulli}(g(\beta^T x))$$

حالا اگر خواهیم نکرد عدل را تحسین ننمود:

جواب این از MLE استفاده کنیم.

MLE: $\hat{\beta}_{ML} = \arg \max_{\beta} L(\beta)$

چون y می خواهد $x^T \beta$ را ببرای y که random چون

fixed

likelihood $L(\beta) = P(y[1], \dots, y[n] | \beta, x[1], \dots, x[n])$

$$= \prod_{i=1}^n P(y[i] | \beta, x[i])$$

جواب بجهوت
ضرب احتمالات
می خواهد می خواهد
متغیر اند.

$$\alpha[i] = g(\beta^T x[i]) = \prod_{i=1}^n \alpha[i]^{y[i]} (1 - \alpha[i])^{1-y[i]}$$

$$= P(y[1]=1 | x[1], \beta)$$

چنان توزیع برآورده

$$\begin{cases} P(y[i]=1 | \beta, x[i]) = \alpha[i] \\ P(y[i]=0 | \beta, x[i]) = 1 - \alpha[i] \end{cases}$$

$$l(\beta) = \sum_{i=1}^n y[i] \log \alpha[i] + (1 - y[i]) \log (1 - \alpha[i])$$

$E[i]$

maximize $l(\beta)$! \Rightarrow + no analytical solution

چون بزم کسی غریب ندارد.

* gradient ascent algorithm

$$\beta := \beta + \lambda \nabla_{\beta} l(\beta)$$



gradient ascent نسبتی حریت کی درست و دلیل gradient descent

$$\frac{\partial l(\beta)}{\partial \beta_j} = \sum_{i=1}^n \frac{\partial E[i]}{\partial \beta_j} = \boxed{\frac{\partial E[i]}{\partial \alpha[i]} \times \frac{\partial \alpha[i]}{\partial z[i]} \times \frac{\partial z[i]}{\partial \beta_j}}$$

← سلسلہ
chain rule

$$= \frac{y[i]}{\alpha[i]} - \frac{1-y[i]}{1-\alpha[i]} \times \alpha[i] (1-\alpha[i]) \times x[j]$$

↓
تو تابع بزرگ

$$\frac{\partial \alpha[i]}{\partial z[i]} = \frac{\partial g(z)}{\partial z} = \frac{\partial}{\partial z} \left(\frac{1}{1+e^{-z}} \right) = \boxed{\frac{o \times (1+e^{-z}) + (e^{-z})(1)}{(1+e^{-z})^2}}$$

HW:

$$= \left(\frac{e^{-z}}{1+e^{-z}} \right) \left(\frac{1}{1+e^{-z}} \right) = \left(\frac{e^{-z}}{1+e^{-z}} \right) (g(z)) \xrightarrow[\text{پس از}]{\text{جمع} + 1 - 1} \frac{(1+e^{-z}-1)(g(z))}{1+e^{-z}} = \left(1 - \frac{1}{1+e^{-z}} \right) (g(z))$$

$$= (1-g(z)) g(z)$$

$\frac{\partial l(\beta)}{\partial \beta_j}$

$$\text{HW: } \frac{y[i] - y[i]\alpha[i] - (\alpha[i] + \alpha[i]y[i])}{\alpha[i](1-\alpha[i])} \times \alpha[i] (1-\alpha[i]) \times x_j[i]$$

$$= (y[i] - \alpha[i]) x_j[i]$$

$$\rightarrow \frac{\partial l(\beta)}{\partial \beta_j} = \sum_{i=1}^n (y[i] - \alpha[i]) x_j[i]$$

↓
ماں مونو تابع بزرگ

$$\hat{y}[i] = \beta^T x[i]$$

فرمول میں بھروسہ فرمول -
بودختا جایی $y[i]$ ، $\alpha[i]$ ، $x_j[i]$ ، β^T

Vector Form:

$$y = \begin{bmatrix} y[1] \\ \vdots \\ y[n] \end{bmatrix} \quad \alpha = \begin{bmatrix} \alpha[1] \\ \vdots \\ \alpha[n] \end{bmatrix} \quad x = \begin{bmatrix} x_1[1] & \cdots & x_d[1] \\ \vdots & & \vdots \end{bmatrix}$$

$$\begin{bmatrix} \frac{\partial \ell(\beta)}{\partial \beta_1} \\ \vdots \\ \frac{\partial \ell(\beta)}{\partial \beta_d} \end{bmatrix} = \nabla \ell(\beta) = \underline{x^T (y - \alpha)}$$

gradient ascent algorithm:

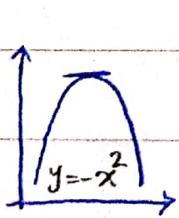
$$\beta = \beta + \lambda \underline{x^T (y - \alpha)}$$

Hessian

$$\nabla^2 \ell(\beta) = - \underbrace{x^T W X}_{\text{SPD}}$$

↓
semi negative definite(SND)

$$W = \begin{bmatrix} w_{11} & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & w_{nn} \end{bmatrix}$$



↓
concave
↓
unique max

$$w_{ii} = \alpha[i](1 - \alpha[i])$$

* ترادیون روشن درجه ۱ است و ممکن است درجه اول را حساب نماید. جایزیتی خودروش



نمیتوانیم یک Logistic که تابع خود را درجه ۲ داشته باشیم.

ML-8

Newton's method (iteratively reweighted least squares)

- این خانه در دروس نیوتن، طاری آن به عنوان این روش نهاده شده است.
- دروس نیوتن می‌باشد gradient descent/ascent
- این از مشتق اول دو مرحله استفاده می‌کند، درجه دیگر در دروس
- همچنان با برآورد دهنده اول سروکار داشتم gradient descent/ascent
- از مشتق دوم در دروس نیوتن سیکل کوک درست چهارمین بیت در دو مرحله از میان
- بینایی تکریبی مانند استفاده از چهارمین logisitic regression که در اینجا بحث خواهد شد

Newton's method

$$f: \mathbb{R} \rightarrow \mathbb{R}$$

نمایشی مثل f را فرض نمایم

the goal: to find x such that $f(x) = 0$.

برای این حالت $f(x)$ کاملاً خود را با این تغیراتی می‌توانیم پیش نمایم.

پس از اینجا

newton's method

{ 1) iterative

2) second order

updating formula :

$$x := x - \frac{f(x)}{f'(x)}$$

ex: find the zero of $x^3 - 8$ $\rightarrow x=2$ analytical

↓ by newton's method $\rightarrow x := x - \frac{x^3 - 8}{3x^2}$

$$x^{(0)} = 4$$

$$x^{(1)} = 2.83$$

$$x^{(2)} = 2.22$$

$$x^{(5)} = 2.001$$

اما مزحل نوین از کجا به دست آمده است (درواقع از بیان مسق اسقاده است) :

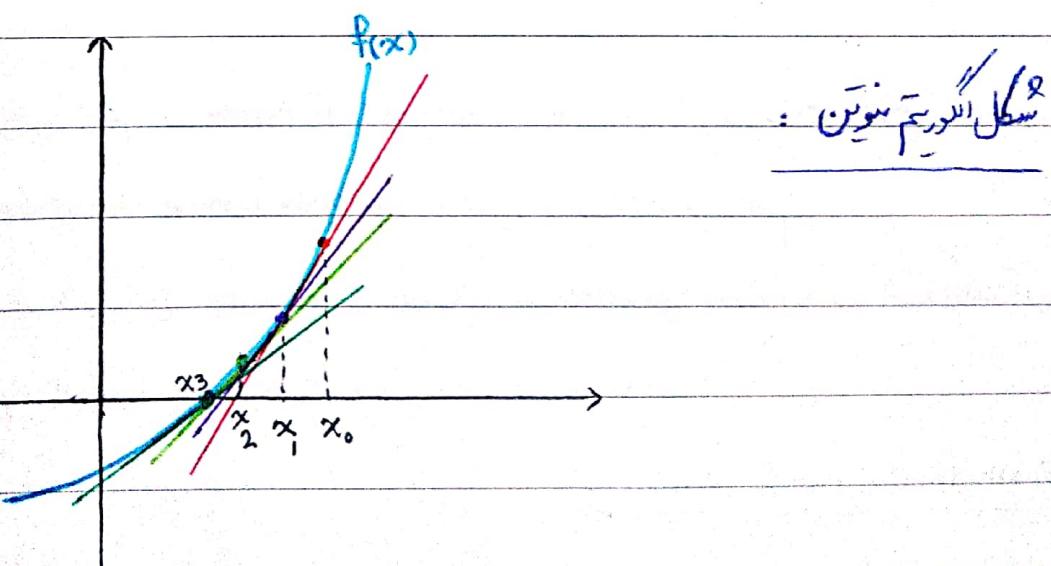
$$f'(x_0) = \lim_{x \rightarrow x_0} \frac{f(x) - f(x_0)}{x - x_0}$$

حال خرض حی کنیم، x ب اندازه کافی بردیک x حست و نایر اس \lim را حفظ کنیم.

$$\Rightarrow f'(x_0) \approx \frac{f(x) - f(x_0)}{x - x_0} \rightarrow \text{جز جمله ایلر } x \text{ حست که باشد.}$$

$$\Rightarrow f'(x_0) \approx \frac{-f(x_0)}{x - x_0} \rightarrow x \approx x_0 - \frac{f(x_0)}{f'(x_0)} \rightarrow \text{آن رابطه هن را صیغه نوین آن.}$$

$$f(x) \approx f(x_0) + f'(x)(x - x_0) \rightarrow \text{درواقع فاضل که بردیک } x \text{ هستد به عنوان خط میان حست.}$$



سطل الگوریتم نوین :

How to maximize $l(\beta)$ using Newton's method?

اگرچه حد این اسکله بارگذش نوین

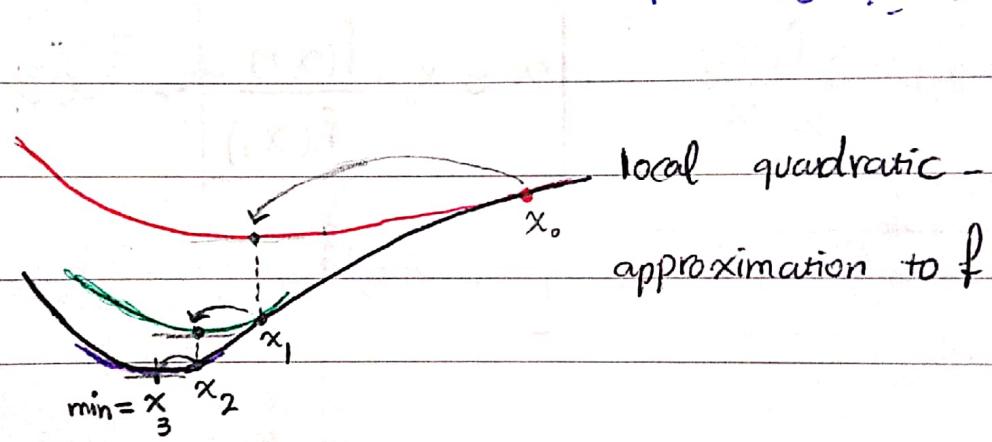
solve: $l'(\beta) = 0$

حسب درجه حرارة جوanalytical بازدش linear regression میتوانستم حل کنم ولی من
با این بازدش عددی حساب کرد logistic regression

$$\ell'(\beta) = 0 \quad (f(x) = \ell'(\beta)) \quad (\text{که چنین یکت} \rightarrow \text{این یکی})$$

$\beta := \beta - \frac{\ell'(\beta)}{\ell''(\beta)}$

در هر نقطه اند قریب درجه ۲ حسنه بخوبی تقریبی که زوایم به تابع $f(x)$ میگیرند
که این در قریب خواهد بود (local) است.



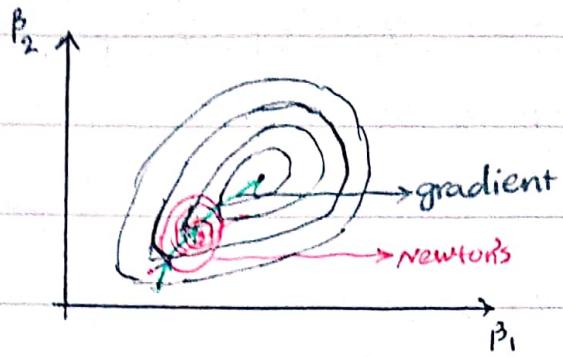
- دسته $f(x)$ را تقریب زدم ، این نسبت تقریب زده شده را بررسی آوردم .
این تقریبی فارجی و درجه ۲ میباشد estimation \hat{x} را بررسی آوردم .
این بازدش هم شبیه بازدش ℓ' است gradient حسنه کند تا بخطاب \min ببرید . فقط جواب آن
برای gradient ℓ' است

Multidimensional case :

$$\beta := \beta - H^{-1} \nabla \ell(\beta)$$

Hessian

: Convex optimization w/ contour plot فرزون كونتار



Taylor's theorem:

$$f(x) \approx f(a) + \nabla f(a)(x-a) + \frac{1}{2} (x-a)^T H(x-a) \rightarrow q(x)$$

.Convex function $f(x)$ is 2nd order derivative

$q(x)$: an approximation of $f(x)$ [around a]

$$q(x) = \frac{1}{2} x^T H x + b^T x + c \rightarrow b = \nabla f - Ha$$

$c = \text{constant}$

↓

$$\nabla q(x) = 0 \rightarrow \nabla q(x) = Hx + b = 0$$

$$\Rightarrow x = -H^{-1}b = -H^{-1}(\nabla f - Ha) \rightarrow x = a - H^{-1}\nabla f$$



خوب بودت آوره، minimization, maximization، (نحوه ایجاد) مینیمیزیشن
درست نیست باید حکم سیم کوئی داشت باشد.

$\nabla^2 q \rightarrow \text{SND}$ (semi negative definite)

جیز در نوع گیری هم max و min هم concave و convex
نمایند $\nabla^2 q$ کوئی minimum و اگرچه صفت خالی نباشد $\nabla^2 q$ از نوع max و min نباشد gradient نبود آن خروج با SND

Multidimensional Case - 2:

in statistics: Fisher's scoring algorithm

گویند score، likelihood اول مسقی داریم

1) gradient descent اسیده کردن gradient ∇f باشد دریافتی شوند

$$2) \text{rather calculation } H^{-1}, \text{ solve } Hy = \nabla f \Rightarrow x_{t+1} = x_t - y$$

$$x_{t+1} = x_t - H^{-1} \nabla f$$

از کاظمی این دیده شدند.

1/10 سعی کرد خوب نشین هست این است که Inverse ماتریس کوئی است ممکن است عددی باشد یا نباشد.

هزینه حسابی و این است که بحاجت عددی robust تر است.

Newton's method for logistic regression:

gradient ascent مدل سریع و آنچه در MLE را با استفاده از logistic regression حل می‌شود آن داشت آورده. احتمال کرد که این تراویح در این لذت و خطا را آن سریع نماید و روش نوین خوبی سریعتر است.

اگر بخواهیم بر روی نوین علیکم همچویم جی و آنرا Hessian likelihood و تراویح را بتوسیم.

$$H = -(x^T w x)$$

$$W = \begin{bmatrix} w_{11} & & & \\ & \ddots & & 0 \\ & & \ddots & \\ 0 & & & w_{nn} \end{bmatrix}$$

$$w_{ii} = \alpha[i] (1 - \alpha[i])$$

$$\alpha[i] = \frac{1}{1 + e^{-\beta^T x[i]}}$$

$$\nabla l(\beta) = x^T \underset{\text{response}}{\uparrow} (y - \alpha)$$

$$\Rightarrow \beta^{\text{new}} := \beta - H^{-1} \nabla l(\beta)$$

$$= \beta + (x^T w x)^{-1} x^T (y - \alpha) =$$

$$= [(x^T w x)^{-1} x^T w x] \beta + (x^T w x)^{-1} x^T w w^{-1} (y - \alpha)$$

$$= (x^T w x)^{-1} x^T w \underbrace{(x \beta + w^{-1} (y - \alpha))}_z$$

$$\beta_{\text{new}} = (x^T w x)^{-1} x^T w z$$

$$\rightarrow z = x \beta + w^{-1} (y - \alpha)$$

weighted linear R این فرایل را در پایه برداشت
ویژه (x → y) $\hat{x} \rightarrow z$ است

adjusted response

درواع خروجی میں جای β_{new} فیورڈیک اگر کو احمد نہیں مارے R سے یہ سائی کسی میں کا نہیں
با روش نہیں کا نہیں با logistic R حل کیم، یعنی جای حل اسکے لئے weighted LM
- logistic R حل کیم جای حل WLR کے iteration پر
- LR حل کیم

at each step : solve weighted least squares.

↓ جبکہ logistic R جس کو دیکھیں گے
Iteratively reweighted least squares

$$\beta^{\text{new}} = \arg \min \mathbf{Z} - \mathbf{X}\beta)^T \mathbf{W} (\mathbf{Z} - \mathbf{X}\beta) \rightarrow \text{WLR}$$

Regularized Logistic Regression :

likelihood function minimize

$$\text{likelihood for logistic R} \rightarrow \hat{\beta} = \arg \min_{\beta} - \sum_i (y[i] \log \alpha[i] + (1-y[i]) \log(1-\alpha[i])) + \lambda \sum_{j=1}^P |\beta_j|$$

* repeated application of weighted LASSO.

Exponential families:

تا سیفه بای حل مسائل مختلف از توزیع کمی متفاوت استفاده کردیم مثلاً ارزوهای گوسین (مزمال)، توزیع برتوالی، ...

حالا مسائل اسخابست که آنکه ارزوهای دستی ایجاد نموده و از توزیع نامیده شدند، می‌باشد که این مسائل از توزیع دوامن متفاوت است، یعنی دوامنی صفر و ۱ است، این مجموعه مدل‌های احتمالی می‌باشد که مدل‌های دوامن متفاوت باشند.

بررسی توزیع دوامن \leftarrow binomial

Linear Regression \leftarrow آنکه باید گوسین باشد

Poisson Regression \leftarrow برای این

* حالا آنکه از توزیع دستی بود، چونه می‌داند راهکارنم چیزی را بدهم؟
چونه می‌دانم آن را تجربه نمایم؟

پس اینها باید با خواهد بود، Exponential distribution

آخر توزیع کمی که، بنابراین، برتوالی، ... خواهد بود و آن توزیع جزو این خواهد بود.

باشد، راصم عنوان parameter estimation ایم در.

Def: An exponential family is a set of distributions with 4 components.

$$P_{\theta}(x) = \frac{1}{Z(\theta)} h(x) \exp(t(\theta)^T s(\theta))$$



آخر توزیعی را توانیم همان سرفت نویسم جزو خواهد بود exponential گیری بجز بود.

$\theta \in R^P$

$\theta = (\theta_1, \dots, \theta_p)$

$x \in R^d$

$Z(\theta) : \Theta \rightarrow [0, \infty]$ partition function

$h : R^d \rightarrow [0, \infty]$

ابن داده را می بینیم

sufficient statistic

$s_i : R^d \rightarrow R$

$t_i : \Theta \rightarrow R$

ex1: Exponential distribution

$$x \sim Exp(\lambda) \quad \lambda > 0$$

$$P_\lambda(x) = \begin{cases} \lambda e^{-\lambda x} & x > 0 \\ 0 & \text{otherwise} \end{cases} \quad \text{or} \quad P_\lambda(x) = \lambda e^{-\lambda x} I(x > 0)$$



$$Z(\lambda) = \frac{1}{\lambda}, \quad h(\lambda) = I(x > 0), \quad t(\lambda) = +\lambda, \quad s(x) = -x$$

ex2: Bernoulli distribution

$$P_\theta(y) = \theta^y (1-\theta)^{1-y} \quad y \in \{0, 1\}$$

solve 1)

$$\downarrow$$
$$= \exp(y \log \theta + (1-y) \log(1-\theta))$$

$$h(y) = I(y \in \{0, 1\}), \quad Z(\theta) = 1, \quad s(y) = [y \quad 1-y]$$

$$t(\theta) = [\log \theta \quad \log(1-\theta)]$$



ازن ماتریسی که باید داشت

$$\text{solve 2)} \quad P_\theta(y) = \exp(y(\log \theta - \log(1-\theta)) + \log(1-\theta))$$

$$= \exp(\log(1-\theta)) \exp\left(y \frac{\log \theta}{1-\theta}\right) \boxed{(1-\theta) \exp\left(y \frac{\log \theta}{1-\theta}\right)}$$

$$Z(\theta) = \frac{1}{1-\theta}, \quad S(y) = y, \quad T(\theta) = \frac{\log \theta}{1-\theta}$$

نمایندهٔ احتمالی خود و در کاربردی مفهومی که داشتیم،
جزوی تابعی آنرا را تعریف کنیم.

ex 3: Gaussian distribution

$$\delta^2 = 1$$

$$\rightarrow P(y) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(y-\mu)^2\right)$$

$$= \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}y^2 + \frac{2\mu}{2}y - \frac{\mu^2}{2}\right)$$

$$= \boxed{\frac{1}{\sqrt{2\pi}} \exp\left(-\frac{\mu^2}{2}\right) \exp\left(-\frac{1}{2}y^2\right) \exp(\mu y)}$$

$$\Rightarrow Z(\mu) = \sqrt{2\pi} \exp\left(\frac{\mu^2}{2}\right), \quad h(y) = \exp\left(-\frac{1}{2}y^2\right), \quad T(\mu) = \mu, \quad S(y) = y$$