

ML-9

Generalized linear models (GLM)

$+ X \rightarrow Y$ (mapping \rightarrow classification or regression)

+ we studied \rightarrow linear regression $Y|X, \beta \sim N(\mu, \sigma^2)$

\downarrow logistic regression $Y|X, \beta \sim \text{Bernoulli}(\theta)$

حالات logistic sigmoid \rightarrow اسقاطه کرد، اعماق از
واقع تابع sigmoid \rightarrow ایجاد آنها است و در غالب تابع $Y|X, \beta \sim \text{Glm}$ تقریبی کرد.

For Normal distribution

linear predictor

$$E(Y|X; \beta) = \mu = g(\beta^T X)$$

$\therefore g(z) = z$ (اعمال حسین کرد) \rightarrow توزیع نرمال

identity

For logistic regression

$$Y|X, \beta \sim \text{Bern}(\theta)$$

وابسته به X و ضریب است.

$$E(Y|X; \beta) = \theta = g(\beta^T X)$$

$$g(z) = \frac{1}{1 + e^{-z}}$$

$$1 \times \theta + \sigma x(1 - \theta) = \theta$$



g : response function \rightarrow map y to average $\beta^T x$

g^{-1} : link function \rightarrow map $\beta^T x$ to y

Ex: logistic regression

$$g^{-1}(\theta) = \beta^T x \rightarrow \log \frac{\theta}{1-\theta} = \beta^T x$$

in GLM framework $y | x, \beta$ follows exponential family distribution

* GLM: given $y | x, \beta$ is from an exp family, GLM framework assists us:

- 1) find g
- 2) estimate β (parameters)

Ex. build a GLM for:

+ response variable (y): # reads of a gene \rightarrow integer

+ input variables (x): gender, treatment/control group

GLM is linear, logistic

Y : Count data \Rightarrow which distribution $Y|x; \beta$?

(Beta binomial) \downarrow ! negative binomial \downarrow

جون پاس دھن کا تقریب دار، واریانس و میانگین میں مساویت نہیں۔

Three elements of GLM:

1) $Y|x; \beta$ follows exp family

$$P(y|x, \beta) = \frac{1}{Z(\theta)} h(y) \exp(t(\theta)s(y)) \rightarrow \text{دھن } \beta, x \text{ سے}$$

$$s(y) = y \rightarrow \text{خرص جی سے } s(y) = y \text{ اسے جون خروجی راستہ ترجیح کرنے۔}$$

for simplicity

$t(\theta)$ \rightarrow Natural parameter

2) we assume $t(\theta) = \beta^T x \rightarrow$ linear predictor
 $\underbrace{\beta^T x}_{\text{design choice}}$

3) $F(x) = E(Y|x, \beta) = g(\beta^T x)$

کس جی پرستی کرنے
کے لئے E کی

generalized

Ex: Bernoulli distribution



$Y|x, \beta \sim \text{Bern}(\theta)$

$$1) F(x) = E[Y|x, \beta] = \theta \rightarrow \text{If } x_1, x_2 \in \Theta$$

$$2) t(\theta) = \beta^T x = \log \frac{\theta}{1-\theta} - \beta^T x \rightarrow \theta = \frac{1}{1+e^{-\beta^T x}} \rightarrow g(z) = \frac{1}{1+e^{-z}}$$

Ex: Normal distribution

$$Y|x, \beta \sim N(\mu, 1)$$

$$1) f(x) = E[Y|x, \beta] = \mu$$

$$2) t(\mu) = \mu = \beta^T x \rightarrow g(z) = z$$

Ex: poisson distribution

$$\text{poisson}(\lambda) \rightarrow p(y|x, \beta) = \frac{\lambda^y e^{-\lambda}}{y!}$$

$$1) f(x) = E[Y|x, \beta] = \lambda$$

$$2) \log \lambda = \beta^T x \rightarrow \lambda = e^{\beta^T x} \Rightarrow f(x) = e^{\beta^T x}$$

$$L(\beta) = \prod_{i=1}^n P(y[i] | x[i], \beta) = \prod_{i=1}^n \frac{\lambda^{y[i]} e^{-\lambda}}{y[i]!} : \text{جتنی } \beta \text{ کے پاس}$$

$$= \prod_{i=1}^n \frac{(\exp(\beta^T x[i]))^{y[i]}}{y[i]!} \exp(-\exp(\beta^T x[i])) \rightarrow \text{likelihood}$$

↓
جتنی hessian & gradient

family: poisson ← glm ← جتنی رسمی جبری، حل Stochastic

از آنکه بی جای ماند دو مسیر استفاده کرد، بهترین

از آنکه بی جای ماند جزئیاتی استفاده Multinomial regression (softmax)

ویا multinomial & binomial باز و توزیع آن

Multivariate Normal distribution

+ also called the multivariate gaussian distribution.

+ univariate $x \sim N(\mu, \sigma^2)$

$$\text{PDF} \rightarrow p(x) = \frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right)$$

+ multivariate $x \sim N(\mu, \Sigma)$ $\mu \in \mathbb{R}^d$, $\Sigma \in \mathbb{R}^{d \times d}$
 covariance matrix
 ↓
Symmetric, SPD



quadratic form

$$\text{PDF} \rightarrow p(x; \mu, \Sigma) = \frac{1}{2\pi^{\frac{d}{2}} |\Sigma|^{\frac{1}{2}}} \exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1} (x-\mu)\right)$$

$$E(x) = \mu$$

$$\text{cov}(x) = E((x - E(x))(x - E(x))^T)$$

جواب


$$\text{cov}(x) = E(x x^T) - E(x) E(x)^T \quad | \text{HW}$$

ref: CS229

در مصل نزدیک ۳ عکس دار ربط با PDF توزیع مزمال در متفاوت است. در هر سه $M = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ است.

و کوواریانس نمک خاترسی قطری است. عکس قطری داریانس را تابعی دارد. $\Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$



برای این ارتباط x_1, x_2 را تابعی داشت که صفر باشد بخواهی x_1, x_2 مستقل نباشند. اگر $+ \beta x_2$ باشد " x_1, x_2 ارتباط مسفعه دارند.



$$\Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = I$$

$$\Sigma = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix} \text{ correlation } x_2$$

$$\Sigma = \begin{bmatrix} 1 & 0.8 \\ 0.8 & 1 \end{bmatrix}$$



$$\Sigma = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} = 2I$$



$$\Sigma = \begin{bmatrix} 0.6 & 0.7 \\ 0 & 0.6 \end{bmatrix} = 0.6I$$

هر چند که بزرگ نباشد

برای این که بزرگ نباشد

\rightarrow نزدیک نزدیک باید، اما + و سه بودن آن بخواهی داریانس correlation




Contour plot:



$$\Sigma = I$$

$$\Sigma = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix}$$

$$\Sigma = \begin{bmatrix} 1 & 0.8 \\ 0.8 & 1 \end{bmatrix}$$



$$\Sigma = \begin{bmatrix} 1 & -0.5 \\ -0.5 & 1 \end{bmatrix}$$

anticorrelation

$$\Sigma = \begin{bmatrix} 1 & -0.8 \\ -0.8 & 1 \end{bmatrix}$$

$$\Sigma = \begin{bmatrix} 3 & 0.8 \\ 0.8 & 1 \end{bmatrix}$$

Var(x_1) Var(x_2)

Symmetric

Discriminative models

+ based on conditional probability \rightarrow $P(Y|X)$


+ logistic regression, kNN, SVM, ... \rightarrow a functional form for $P(Y|X)$

\Rightarrow estimate its parameters

$$\text{Ex: } P(Y|X) = f(X) = \frac{1}{1 + e^{-\beta^T X}}$$

Generative models :

+ a statistical model for $P(x, y)$



ردیکریوئن کے براسن اس اور خوف این اسٹ نہیں تابع ایجاد کئیں۔

دل generative، ہم X دھم 2 را model کر دے اس۔ یعنی $\pi_{\theta}(x_1, x_2)$ دو معنی ہے
X را مخصوص ہی کند، دلگھ کو اس کی جزوی ایجاد کند، (ریکورڈ میں متعدد ہے اسی سبب

اعاده درجاتی Discriminative حسن امکانی وجود نداشت.

< خنک گرایی ساخت نمونه های جدید از آن به کار ریختن < Generative models

ان درجا join اس واطبع x, y هم ذریعه

face detection (II) \leftarrow \rightarrow

2) ساخت صور حجمی انسان face

LDA \bar{w}_k

$$+ p(x,y) = p(x|y) p(y)$$

or

$$P(Y|X) P(X)$$

امن لحمة استعداد في المدارس

دولت حاصلہ کی آن سنت تراویث

relative frequency
estimate from train data

+ use Bayes' rule to compute $P(Y|X)$

+ example : linear Discriminative analysis

Naïve bayes

ML-10

Linear Discriminant Analysis

+ a generative model

+ Data $\{(x[1], y[1]), \dots, (x[n], y[n])\}$

+ model distribution of x for each class separately.

$P(x|Y=k)$ and $P(y)$

برای هر کلاس x از کدام توزیع برآورده شود.

+ then use Bayes' rule $P(Y=k|x) = \frac{P(x|Y=k)P(Y=k)}{P(x)}$


بهترین k را می‌توانیم با محاسبه $P(Y=k|x)$ بدست این معیار تعیین کرد.

برای $P(Y|x)$ می‌توانیم Logistic regression را در نظر بگیریم.

هدف : با این معرفت که داشتم ۲ حرزا است و خواهیم رای صور حمزه را بی دو تا دلخواه.

با زعم.





*different choices for $x|Y=k$

متى (أو) X دارم بروتة باشد ياست.

فرض عمل LDA ← فرض جي كند توزيع زفال اول.

$$x|Y=k \sim N(\mu_k, \Sigma)$$

↓ shared between our classes

$$P(x|Y=k) = \frac{1}{2\pi^{d/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x-\mu_k)^T \Sigma^{-1} (x-\mu_k)\right)$$

$$P(Y=k) = \pi_k$$

$$\sum \pi_k = 1$$

$$\text{و } k = \{1, 2, 3\}$$

multinomial

فقط 3 طبقات

$$G(x) = \underset{k}{\operatorname{argmax}} P(Y=k|x)P(Y=k) \xrightarrow{\text{معنوي}} \log$$

$$\rightarrow \log p(x|Y=k) + \log \pi_k$$

$$\alpha - \frac{1}{2} (x - \mu_k)^T \Sigma^{-1} (x - \mu_k) + \log \pi_k$$

~~$$\alpha = -\frac{1}{2} (x^T \Sigma^{-1} x - x^T \Sigma^{-1} \mu_k - \mu_k^T \Sigma^{-1} x + \mu_k^T \Sigma^{-1} \mu_k) + \log \pi_k$$~~

فون كارلا جونز

$$\alpha x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log \pi_k = \delta_k(x)$$

\downarrow
 x, K از مجموعی داشت.

اصغر بگیرید، هر کدام خودی بسته داشت. $\delta_1, \delta_2, \delta_3$

linear in $x \rightarrow c_0 + c_1 x_1 + c_2 x_2 + \dots + c_d x_d$

How to estimate parameters?

$$\mu_1 \in \mathbb{R}^d, \mu_2 \in \mathbb{R}^d, \Sigma \in \mathbb{R}^{d \times d}, \pi_1, \pi_2$$

\uparrow
 $\frac{d^2-d}{2}+d$

{ features بخوبی
 $x_2, x_1 \leftarrow [\cdot]$

Likelihood function: $L(\theta)$

$$L(\theta) = \prod_{i=1}^n p(x[i], y[i] | \theta)$$

$$\rightarrow l(\theta) = \underbrace{\sum_{i=1}^n \log p(x[i] | y[i])}_{\text{Gaussian} \rightarrow \mu_k, \sum} + \underbrace{\sum_{i=1}^n \log p(y[i])}_{\text{multinomial} \rightarrow \pi_k} \quad \sum \pi_k = 1$$

$$\hat{\mu}_k, \hat{\Sigma}, \hat{\pi}_k = \arg \max \ell(\theta)$$

$$n_k = \sum_{i=1}^n I(y[i]=k) \quad \hat{\pi}_k = \frac{n_k}{n}$$

$$\mu_k = \left(\sum_{i=1}^n x[i] I(y[i]=k) \right) / n_k$$

$$\hat{\Sigma} = \sum_{k=1}^K \sum_{i=1}^n \frac{I(y[i]=k)(x[i]-\hat{\mu}_k)(x[i]-\hat{\mu}_k)^T}{n-k}$$

Quadratic discriminant analysis (QDA):

+ separate Covariance matrix for each class.

$$\Sigma_1, \Sigma_2, \Sigma_3, \Sigma_4, \dots, \Sigma_K$$

دالة الـ log-likelihood هي $x^T \Sigma^{-1} x + \log |\Sigma|$

$$S_k(x) = -\frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k) + \log \pi_k$$

↓ quadratic in x

+ # of parameters is much higher → overfitting

Regularized QDA: → ridge, LASSO

$$\hat{\Sigma}_k(\alpha) = \alpha \hat{\Sigma}_k + (1-\alpha) \hat{\Sigma}_{LDA}$$


↑ QDA ↑ LDA

تَقْسِيمٌ حَكِيمٌ ← تَعْوِيذٌ آنفَابَسَتْ صَفَرٌ بُرُودَ ← حَدَلْ سَادَةَ
 بَعْثَتْ خَطْرَشَدَنْ حَسَرَوَدَ

(LDA)

دَلْ بَعْيَهَ كَرَهَ كَوَرَ

Graphical model



Näive Bayes classifier

+ a family of models


+ A Näive assumption $P(X|Y) = P(x_1|y)P(x_2|y) \dots P(x_p|y)$

* Conditionally independent given Y

$$+ \text{Baye's rule} \rightarrow P(y|x) = \frac{P(x_1|y)P(x_2|y) \dots P(x_d|y)P(Y)}{P(x)}$$

$$= \frac{P(Y) \prod_{i=1}^d P(x_i|y)}{P(x)}$$

$$\hat{y} = \operatorname{argmax}_y P(y|x)$$



Estimation : Likelihood

+ parameters $P(Y) \rightarrow P(x_j|y)$

..... x_j خصائص اسماً بنوع $P(x_j|y)$

beroulli \leftarrow binary $\leftarrow x_j$

متغير متعدد \leftarrow متغير $\leftarrow ..$

multinomial \leftarrow categorical $\leftarrow ..$

Neg Binom \leftarrow بواسن \leftarrow Count data $\leftarrow ..$



+ distribution of $p(x_j|y)$ depends on data types.

$$L(\theta) = \prod_{i=1}^n P(x_{[i]}, y_{[i]}) = \prod_{i=1}^n \underbrace{P(x_1_{[i]} | y_{[i]}) \dots P(x_d_{[i]} | y_{[i]})}_{\text{vector } P(x_{[i]} | y_{[i]})} \times P(y_{[i]})$$

$$\Rightarrow l(\theta) = \sum_{i=1}^n \log P(x_1_{[i]} | y_{[i]}) + \sum_{i=1}^n \log P(x_2_{[i]} | y_{[i]})$$

$$+ \dots + \sum_{i=1}^n \log P(x_d_{[i]} | y_{[i]}) + \sum_{i=1}^n \log P(y_{[i]})$$

..... x_j خصائص اسماً دل دفعه ... ارجاع طبق نتائج \leftarrow feature \leftarrow پارامتر



+ we can estimate parameters independently.

<u>Ex:</u>	<u>A(age)</u>	<u>Smoking(S)</u>	<u>Lung Cancer(L)</u>
	1	0	1
	1	0	0
	0	1	0
	0	1	1
	1	1	1
	1	0	0
	0	0	0

$$\arg \max p(L|A, S)$$

$$A, S \rightarrow X$$

$$L \rightarrow Y$$

*predict the class for $S=1, A=1$

$$P(L=1 | S=1, A=1) \propto p(A=1 | L=1)^* p(S=1 | L=1)^* p(L=1)$$

$$P(L=0 | S=1, A=1) \propto p(S=1 | L=0)^* p(A=1 | L=0)^* p(L=0)$$

$$\left\{ \theta_L = P(L=1) = \frac{3}{7}, \theta_{A|L=1} = P(A=1 | L=1) = \frac{1}{3} \right.$$

$$\left. \theta_{A|L=0} = P(A=1 | L=0) = \frac{1}{2}, \theta_{S|L=1} = P(S=1 | L=1) = \frac{2}{3} \right.$$

$$\theta_{S|L=0} = P(S=1 | L=0) = \frac{1}{4}$$

Review MLE (in)

Laplace correction

$$P = \frac{o}{3} = \frac{o+1}{3+2} = \frac{1}{5}$$



باصنح لالپس جی تو انہ اثر احالت سے صفر رکھ کر نہیں۔



$$P(X=1 | Y=k) = \frac{1 + \sum I(x[i]=1, y[i]=k)}{\sum_{i=1}^n I(y[i]=k)}$$

pseudo count \leftarrow $(1+k) + \sum_{i=1}^n I(y[i]=k)$

QDA, LDA جاں تھوڑی اور



$$\Sigma_1 = \Sigma_2$$

$$\Sigma_1 \neq \Sigma_2$$

- bayes classifier

- QDA

- LDA

QDA، (نکل مخفی است و قرآن کردار نہیں) $\Sigma_1 \neq \Sigma_2$ نہیں شد (نکل مخفی است) $\Sigma_1 = \Sigma_2$ bayes classifier

bayes classifier کا راتر اسست وہ bayes classifier کا راتر اسست وہ LDA نہیں شد

