

## ML 11

### Constrained optimization

• مسأله ازدحامی محدودیت داری مسأله محدودیت داری مسأله constrained optimization  
..., metabolic networks, linear programming, PCA & SVM  $\rightarrow$  "in"

unconstrained opt (مسأله ازدحامی محدودیت نداری) optimise  $f(x)$  که اینجا محدودیت نداری  
(..., Newton, gradient descent)

\* اینجا لازم است که محدودیت های محدودیت داری باشند

• محدودیت convexity  $\rightarrow$  opt.,  
convex optimization  $\rightarrow$  is important  $\rightarrow$  because it is a global answer.  
(global optimum)


### Convex set

Def: A set  $C$  is a convex set if any  $x, y \in C$  &  $0 < \theta < 1$ .




$$\boxed{\theta(x) + (1-\theta)y \in C}$$

Example: A convex set



• اگر  $x, y \in C$  باشند، آنها را می توان  $\theta$  بین هم درست کرد.  
 $\theta$  بین صفر و ۱ باشد.  
 $\theta$  جای صفر  $\leftarrow$  روی  $x$

A non-convex set




سیستم ML، convex set (گشته)

Convex set،  $f(x)$  is convex if  $\{x \mid f(x) \leq c\}$  is convex

Constrained region،  $x \in \mathbb{R}^n$  such that  $g_i(x) \leq 0, i = 1, 2, \dots, m$  is called constrained region

usually region denoted by constraints.




this shape has 3 constraint

## Convex function

Def: a function  $f$  is a convex function if for all  $x, y$  in the domain of  $f$  and  $0 \leq \theta \leq 1$ , we have:

$$f(\theta x + (1-\theta)y) \leq \theta f(x) + (1-\theta)f(y)$$



bowl-like  $\rightarrow$  you can find min very easily!

## concave function

Remark: A concave function is the negative of a convex f.



you can find max very easily.

اگر max, min کی تابع از زمان بر این تابع concave  $\rightarrow$  convex

کوئی تابع کوئی در جهاد دل را بخواهد.

مثال اگر convex function کو squared loss function:

$\rightarrow$  linear regression,  $\rightarrow$   $\min \sum (y_i - \hat{y}_i)^2$

convex  $\rightarrow$  design (ساخت) function  $\leftarrow$  likelihood,  $\rightarrow$   $\ln L$

کوئی concave!

کوئی non-convex Neural net کو مثل هم درست نمایند.

concave  $\leftarrow$  convex (ارجاع) design  $\rightarrow$   $\min L$

ایجاد (نمایش)

کوئی global min & local min کو  $\leftarrow$   $\min$  convex (ارجاع)\*

## Theorem :

if  $f(x)$  is twice differentiable,  $f(x)$  is convex,

if and only if: Hessian  $\nabla^2 f$  is PSD.

$$\Delta^2 f = \begin{pmatrix} 2 \\ \vdots \end{pmatrix} \leftarrow x^2 : \text{ماں}$$




importance:


+ for convex functions, all local min are global min.

+ easy to optimize.

+ objective functions in ML  $\rightarrow$  designed to be convex.



### Review- Unconstrained optimization



لطفاً میخواستم چیزی در opt دیگر نمایش نمود که جیسے بسیار چیزی نمایش نمود کنم۔  
و حکمت در خلاف آن است که میخواهی داشتم فرم فرم میگردید که میتواند  
و میتواند non-convex باشد که همچنان که min یعنی پائین رفته باشد

$\min f(x)$

$$\text{ex1: } \min_x x^4 + 5x^2 - 7x + 3 \xrightarrow{\text{optimize}} \min$$

ex2: a quadratic function:

$$\min_{x_1, x_2} f(x_1, x_2) = \frac{1}{2} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}^T \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} - \begin{bmatrix} 5 \\ 3 \end{bmatrix}^T \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

↓ .  $C = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$

$$f(x_1, x_2) = \frac{1}{2} x^T Q x + C^T x \quad \text{quadratic form}$$

↓

$$\nabla f = Qx + C$$

→  $\min$  • Analytical & Newton • gradient descent

### Constrained optimization


نیز ساردن کے میں اسی طبق کے جواباً فتحاً حوتاندید نہیں

•  $\text{highlight}$

- optimal solution

• اسی کے لئے اسی کے لئے

- objective fun = مدار راستہ



دوزنم داشته که درین مفهوم دو نوع هستند LASSO  
بروی constrained opt

$$\begin{array}{l} \min_x f(x) \\ \text{s.t. } \begin{cases} g_i(x) \leq 0 \\ h_j(x) = 0 \end{cases} \end{array}$$

for  $i=1,2,\dots,m$   
for  $j=1,2,\dots,t$

: محدود شده نوع هستند Constrained

1) نهادی که به کوچکتر صادی تبدیل می شود.

2) سادی

آنچه ایجادی را پس از این دو چون می توان آن را

ب دونهادی هم تبدیل کرد.

$$h_j(x) = 0 \rightarrow \begin{cases} h_j(x) \leq 0 \\ h_j(x) > 0 \end{cases}$$


آنچه ایجادی lagrangian  $\rightarrow$  سادی constrained

$$\text{ex: } \min 2x_1 + x_2$$

$$\text{s.t. } x_1 \leq 3, x_2 \geq -1$$

$$x_2 - x_1 - 1 \leq 0$$

(a linear program)



$$-x_2 - 1 \leq 0$$

all inequalities

convert to

"less than" inequalities



## Convex optimization problem :

$$\min_x f(x)$$

$$\text{s.t. } g_i(x) \leq 0$$

$$h_j(x) = 0$$

اين مسئلہ دوسرے درجہ  
Convex opt

(1) \*  $f, g_i$  are convex functions

مبنی علیو ریختنی  $f$  و  $g_i$  دوسرے درجہ

(2) \*  $h_j(x) = 0$  constraint

(2) \*  $h_j(x) = 0$  is convex set

اعتدل این اسک ناگزیری اشتینون تعریف شود براحتی قابل حل است.

همچنان SVM, ML, کاربرد دارد.

convex opt problem? overfitting بروز خوبی شود و برابر باشی

نمایشی شود.

## Linear programming :

Involves Convex opt prob از جمله Linear programming

اسیدهای متابولیک metabolic networks

+  $f, g, h$  are linear functions. (Affine  $\rightarrow$  عدم ازینگ) (linear  $\rightarrow$  میتوان)

Univariate Affine function

$$\begin{aligned} & \min c^T x \\ & \text{s.t. } Ax \leq b \end{aligned}$$

محدودیتی دنور constraint

$$\left. \begin{array}{l} A \in \mathbb{R}^{m \times d} \\ b \in \mathbb{R}^m \end{array} \right\} \begin{array}{l} \rightarrow m \rightarrow \text{constraints} \\ \rightarrow d \rightarrow \text{variables} \end{array}$$

$$\min \begin{bmatrix} 2 \\ 1 \end{bmatrix}^T \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

$\leftarrow m=2, d=2 \leftarrow \text{linear programming}$

$$\begin{array}{l} \text{s.t. } x_3 \leq 3 \\ x_2 \geq -1 \end{array}$$

$$\begin{array}{l} \Rightarrow \text{s.t.} \\ \begin{bmatrix} 1 & 0 \\ 0 & -1 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \leq \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix} \end{array}$$

## Quadratic programming

• not linear programming; it's quadratic

$$\min_x \frac{1}{2} x^T Q x + c^T x$$

$$\text{s.t. } Ax \leq b$$

Q: PD matrix


objective: quadratic

linear constraint (Affine)

$$\min_x \frac{1}{2} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}^T \begin{bmatrix} 2 & 1 \\ 1 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} 5 \\ 3 \end{bmatrix}^T \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

$$\text{s.t. } \begin{bmatrix} 1 & 0 \\ -1 & 0 \\ 0 & 1 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \leq \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}$$

box constrained



Corner  $\rightarrow$  linear programming  
Quadratic  $\rightarrow$ \*

## Converting constrained problem to unconstrained problems:

$$\min_x f(x)$$

$$\text{s.t. } g_i(x) \leq 0 \quad i=1, 2, \dots, m$$

simple idea:  $J(x) = f(x) + \sum_{i=1}^m \gamma(g_i(x))$

$\min J(x) \rightarrow$   $\min f(x) + \min \gamma(g_i(x))$

$$\gamma(z) = \begin{cases} 0 & z \leq 0 \\ \infty & z > 0 \end{cases}$$

$$J(x) = \begin{cases} f(x) & \text{all constraints satisfied} \\ \infty & \text{ow} \end{cases}$$

$\downarrow$   
not practical  $\rightarrow$  but  $\min_x J(x) \rightarrow$  Lagrangian  
constrained

## Lagrangian:

idea: replace  $\gamma$  with a linear function.

$$L(x, \alpha) = f(x) + \sum_{i=1}^m \alpha_i g_i(x)$$



$\alpha_i \geq 0$  are called Lagrange multipliers. (also called dual variable)

$$L(x, \alpha) = f(x) + \alpha^T g(x)$$

مکانیک دکتر فرم حسون رام

$$J(x) = \max_{\alpha \geq 0} L(x, \alpha) = \begin{cases} f(x) & \text{all satisfied} \\ \infty & \text{ow} \end{cases}$$

## Lagrangian duality :

optimization problem in  $x$   $\xrightarrow{\text{minimize}}$  optimization problem in  $\alpha$

$x$ : primal variables

$\alpha$ : dual variables

primal problem : minimize  $L_p(x)$

$$L_p(x) = \max_{\alpha} L(x, \alpha)$$

↓

$$\boxed{\min_x \max_{\alpha \geq 0} L(x, \alpha)} \rightarrow \text{optimal value}$$

dual problem :  $\max_{\alpha} L_D(\alpha)$

$$L_D(\alpha) = \min_x L(x, \alpha) \rightarrow \text{lagrange dual function}$$

concave function

$$\boxed{\max_{\alpha \geq 0} \min_x L(x, \alpha)}$$

upper bound

• درایه کسینی هم دارد و مکت سرایع تحلیل آن  
جواب اکسان باشد.

• ترکیب این دو ترکیب را مینیمیزیشن از dual می‌گیریم.  
• انتقال primal به dual (کل تراویح (max) مینیمیزیشن primal)

$$d^* = \max_{\alpha \geq 0} \min_x L(x, \alpha) \leq p^* = \min_x \max_{\alpha \geq 0} L(x, \alpha)$$

• اگر  $p^* = d^*$   $\leftarrow$  design، قابل پیغامد  
 $\boxed{p^* = d^* = L(x^*, \alpha^*)}$   $\rightarrow$  strong duality

+ f, g are convex }  $\rightarrow$  strong duality  
 other criteria

: کل پرسیو dual یا نیز

+ if  $\min_x L(x, \alpha)$  is easy  $\Rightarrow$  overall problem

easy

Cause

$L(\alpha)$  is a concave function

+ easier in some problems

• easy for primal prob

+ # constraints  $\leq$  features  $\rightarrow$  min  $\rightarrow$  max

• easy for dual prob

ML-12

Review  $\rightarrow \min_x f(x)$

$$\text{s.t. } g_i(x) \leq 0 \quad i=1, 2, \dots, m$$

$$L(x, \alpha) = f(x) + \sum_{i=1}^m \alpha_i g_i(x) = f(x) + \alpha^\top g(x)$$

## Lagrangian duality

primal problem :  $\min_x L_p(x)$

$$s.t \quad L_p(x) = \max_{\alpha \geq 0} L(x, \alpha)$$

dual problem :  $\max L_D(\alpha)$


$$\text{s.t. } \min_{\alpha} L(\alpha) = \min_x L(x, \alpha)$$

$$\text{strong duality} \rightarrow p^* = d^* = L(x^*, d^*)$$

## Linear programming:

$$\min \mathbf{c}^T \mathbf{x}$$

$$s.t \quad Ax \leq b$$



حاصل فریب اس د کہ مدد سے رحل این -  
مددوار گسانی اس .

جواب ۱۰ صفحه

$$\min - \begin{bmatrix} 5 \\ 3 \end{bmatrix}^T \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

subject to

$$\begin{array}{|c c c|} \hline & 2 & 2 & 1 \\ & 2 & -4 & \\ \hline & -2 & 1 & \\ & 0 & -1 & \\ & 0 & 1 & \\ \hline \end{array} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \leq \begin{bmatrix} 3 \\ 3 \\ 8 \\ 5 \\ -1 \\ 8 \end{bmatrix}$$

$$\text{Lagrangian: } L(x, \alpha) = C^T x + \alpha^T (Ax - b)$$

$$= (C + A^T \alpha)^T x - \alpha^T b$$

the dual opt problem:  $\frac{\partial L}{\partial x} = 0 \quad \min_x L(x, \alpha) \rightarrow C + A^T \alpha = 0$

$$L_D(\alpha) = -\alpha^T b = -b^T \alpha$$

dual problem:

$$\max_{\alpha} -b^T \alpha$$

s.t.

$$\left\{ \begin{array}{l} \alpha \geq 0 \\ C + A^T \alpha = 0 \end{array} \right.$$

روزگار از مسائل این  
رایانه ای داریم و مسأله  
کوئدراطیکی دارد

m constrained  $\rightarrow$  dual

d. feature  $\rightarrow$  primal

فرم: HW  
جواب دادنی: quadratic, رایانه ای dual

[مسأله کوئدراطیک را بصرخواری دهن و مسئله کوئدراطیکی را هم باقی بگذارید]


[فرم: L\_D(\alpha), فرم lagrangian]



## KKT Conditions (Karush-Kuhn-Tucker)

differentiable ↑


In unconstrained optimization:  $x^*$ : optimal point  $f(x)$



kkt conditions are similar conditions for constrained opt.

نحوه ایجاد

جی دلایم کے درجے میں optimal مسنو اول صفر اسٹ (اگر مسنو بزرگ باشد) دلی اگر مسنو اول صفر بزرگ، آسال لزو ما جی وانیم کو سم آن نظر اسٹ؟ خر کت سڑاچی جی دلایم اسی موضع دلیں سسٹم، اسی عصیر اسی امر حداچی سنیں۔



دلت  $x^*, \alpha^*$  کے درجے میں KKT conditions

If  $(x^*, \alpha^*)$  are primal & dual solutions



$x^*$  &  $\alpha^*$  satisfy KKT conditions



## KKT conditions:

1. primal constraints  $\rightarrow g_i(x^*) \leq 0, i=1, \dots, m$

2. Dual constraints  $\rightarrow \alpha_i^* \geq 0, i=1, \dots, m$

3. complementary slackness  $\alpha_i^* g_i(x^*) = 0 \rightarrow$  جایدزیت  
عنصری برقرار است؟  
optional HW  $\uparrow$  proof?

4. stationary  $\nabla F(x^*) + \sum_{i=1}^m \alpha_i^* \nabla g_i(x^*) = 0$   
 $\nabla F(x^*) = 0$  دستگاه محدوده  
محدوده

If  $x^*$  and  $\alpha^*$  are primal & dual solutions  $\rightarrow$   $x^*$  &  $\alpha^*$  satisfy KKT conditions

{ differentiable $f, g_i(i)$ } strong duality	necessary condition	$x^*$ & $\alpha^*$ satisfy KKT conditions

دual, جواب پذیر هست.  $\rightarrow$  جواب که جواب پذیر هست by design باشد.

دیگری قضاوی دستributum qualification constraints داریم و نرم می‌سازیم  
Slater's condition

وطبق این قضایا می‌توان بادست  $f, g$  مخصوص کرد.

لاین.



strong duality حالت ازندی حل سیم حس داشت linear programming،  
 feasible space،  $f$  convex +  $f, g$  slater's condition مطابق با  
 strong duality.

ساده،  $f, g$  کوچک است SVM  
 - strong duality و تابع  $f$  convex وجود دارد  
 -  $\alpha^*$  و  $x^*$  و  $\lambda^*$  strong duality  
 KKT conditions، صدق حکم

sufficiency of KKT conditions:

$\tilde{x}$  and  $\tilde{\alpha}$  satisfy KKT conditions  $\rightarrow$   $\tilde{x}, \tilde{\alpha}$  are primal  
 & dual solutions  
 (zero duality)


strong duality صفر است = duality gap

practical implications  $\rightarrow$  convergence check

+  $\alpha_i = 0$  for some constraints.

آخر.  $\alpha_i = 0$ ،  $i$  سطح اس (بعضی جای) و  $i$  constraint،  $i$  که مطابق شد وقت لستم

شیوه بین دو قطعه optimal (فضل سنتز و ارز جایی) شوند تا نتیجه در آن نباشد پس  $\alpha_1 = 0$   
 (۱)  $\Rightarrow$   $\alpha_1 = 0$  در بین دو قطعه optimal (فضل ارز جایی) آنها حوزه ایست.



for  $c_1, c_2, c_3 \rightarrow x_i = 0$

for  $c_{2,3} \rightarrow \alpha_i \neq 0$


$$g_s(x^*) < 0$$

## coordinate-wise optimization :

برقی ازروش عی learning جبریابی ازروش optimization SVM رایجیم حوزه هندسه ایم سیای ازاس درش exted استفاده می کرد.

اُن درش بے subgradient داسیئہ اھست . (LASSO جو جملہ)

## subgradient :



$$f(b) \geq f(a) + \nabla f(a)^T(b-a)$$

← if  $f$  is convex

(linear approximation always underestimates f.)


از ترکیب دو مجموعه مغلوب می‌شوند = subgradient

\* Subgradient is generalization of gradient to non-differentiable points.

- subgradient of convex  $f$  is any  $v$ .

$$f(b) \geq f(a) + v(b-a) \text{ for all } b$$

جایگزین




$$\partial f(x) = \begin{cases} 1 & x > 0 \\ [-1, 1] & x = 0 \\ -1 & x < 0 \end{cases} \quad f(x) = |x|$$

اسیمهٹیک

ex: let  $f_1$  &  $f_2$  be convex and differentiable.

$$f(x) = \max(f_1(x), f_2(x))$$

$$\partial f(x) = \begin{cases} \nabla f_1 & f_1(x) > f_2(x) \\ \nabla f_2 & f_2(x) > f_1(x) \\ \text{any point on} \\ \text{line segment} & f_1(x) = f_2(x) \\ \text{between } \nabla f_1 \text{ and } \nabla f_2 \end{cases}$$



## Coordinate-descent algorithm : (coordinate-wise opt)

+ simple, efficient and scalable.

من اکثر سبب برداشت gradient descent می باشد، چنانچه توابع دارای loss function را با آن opt کرد

$$+ \min_{\beta} L(\beta_1, \dots, \beta_d) \rightarrow \text{unconstrained minimization}$$

### Algorithm :

iterate until convergence {

for  $i=1, \dots, d$

$$\beta_i = \arg \min_b L(\beta_1, \dots, \beta_{i-1}, b, \beta_{i+1}, \dots, \beta_d)$$

} هر دوی فضیراً که نسبت و بقیه دنبای تکمیل کرده اند، می خواهند از این حوزه خارج شوند.  
↓  
coordinate-wise


+ keep all other variables fixed.

+ one-at-a-time not all-at-once

+ coordinate-wise min  $\Rightarrow$  global min

convex  $\Rightarrow$  global min

نحوه این الگوریتم هست که در این آنچه مرتفع است



LASSO



متق زیر اس ای که صفت عزیز موارد جایز دارد

زیر L1 norm

+ separable non-smooth

$$\underbrace{(Y - XB)^T (Y - XB)}_{\text{موارد}} + \lambda \underbrace{\|\beta\|_1}_{\text{موارد}} \\ \underbrace{\text{separable}}_{\text{separable}}$$